



**Mastère Data Engineer
Titre RNCP 39586**

**Ingénieur en Science des Données – Spécialité
Infrastructure Data**



RENDU BLOC 2 – ANALYSER, ORGANISER ET VALORISER DES DONNEES

Août 2025

**Sujet : Conception d'une Architecture Data pour
Analyser les Consommations d'Energie
Réelles et la fiabilité des DPE des logements en France**

Réalisé par :
GBENOU Merveille Féréol Mahugnon

Sommaire

<i>Introduction</i>	3
A - ANALYSE DES DONNÉES	4
1 - <i>Analyse du besoin</i>	4
2 - <i>Plan d'analyse</i>	6
3 - <i>Requêtes et résultats de la collecte</i>	7
4 - <i>Méthodologie de tests statistiques</i>	10
B - VISUALISATION DES DONNÉES ET INTERPRÉTATION	11
1- <i>Visualisation des données et interprétation</i>	11
2- <i>Recommandations</i>	17
C - SUPPORT ET ACCOMPAGNEMENT DES UTILISATEURS	18
1 - <i>Support de formation</i>	18
2 - <i>Documentation technique</i>	23
CONCLUSION	29
ANNEXE	30
SOURCES, ARTICLES ET ÉTUDES SIMILAIRES EXISTANTES	30
FIGURES	31

Figures

Figure 1: Importation et collecte des données complètes (silver data).....	8
Figure 2 : Aperçu des indicateurs calculés	9
Figure 3 : Carte de la France avec les points de livraison Enedis	11
Figure 4 : PDL Enedis - ciblé sur le département de l'Oise (60) – DPE de la ville de Compiègne	11
Figure 5 : Graphiques lot 1 - DPE et comparaison des consommations d'électricité	12
Figure 6 : Graphiques lot 2 - consommations d'électricité et différences par classe DPE	13
Figure 7 : Graphiques lot 3 - comparaisons absolues.....	13
Figure 8 : Graphiques lot 3 - comparaisons relatives.....	14
Figure 9 : Tests statistiques - comparaison de la moyenne de deux distributions appariées	14
Figure 10 : Courbes d'apprentissage et Importance des variables dans le modèle	16
Figure 11 : Exemple d'inputs pour le modèle - étude de cas	16
Figure 12 : Résultat simulation gains après rénovation énergétique – étude de cas	17
Figure 13 : Configuration ETL - variables d'environnement	27
Figure 14 : Pipelines d'ETL	31
Figure 15 : Schéma de la base de données.....	31
Figure 16 : Routes avec les requêtes préparées pour le dashboard client	31
Figure 17 : Comparaisons résultats modèles de régression	32
Figure 18 : Analyse exploratoire sur colab – 1.....	32
Figure 19 : Analyse exploratoire sur colab – 2	32
Figure 20 : Analyse exploratoire sur colab - 3.....	33

Introduction

Dans un contexte d'urgence climatique et de flambée des prix de l'énergie, la rénovation énergétique des bâtiments résidentiels constitue un enjeu majeur pour atteindre la neutralité carbone à l'horizon 2050. Le secteur du bâtiment, responsable de près de 45% de la consommation énergétique nationale française, représente un potentiel considérable d'économies d'énergie et de réduction des émissions de gaz à effet de serre. Face à ces défis, les propriétaires de logements sont confrontés à une question cruciale : quel est le retour sur investissement réel des travaux de rénovation énergétique ? Pour éclairer leurs décisions, ils disposent aujourd'hui du Diagnostic de Performance Énergétique (DPE), un outil réglementaire qui évalue la consommation théorique d'un bâtiment selon une classification allant de A (très performant) à G (très peu performant). Cependant, l'écart entre ces estimations théoriques et les consommations réelles mesurées demeure largement méconnu, créant une incertitude pour les décisions d'investissement.

Ce papier représente le second livrable des quatre blocs de rendus dans le cadre de la certification RNCP Ingénieur en Science des Données – Spécialité Infrastructure Data dédié à l'analyse des données. Les résultats de cette analyse s'adressent aux ménages propriétaires en France métropolitaine qui cherchent à quantifier précisément les économies mensuelles en euros qu'ils pourraient réaliser en engageant des travaux de rénovation énergétique. Les données sont collectées sur tous les logements du territoire et l'étude de cas se concentre sur le département de l'Oise (60) avec ses spécificités climatiques.

L'originalité de cette recherche réside dans le développement d'un outil de collecte de données industrialisé, automatisé depuis trois sources complémentaires et hétérogènes pour créer un jeu de données unique, exploitable et reproductible. D'une part, les données de consommation électrique réelles issues du réseau de compteurs communicants Linky d'Enedis, qui constituent la mesure objective des comportements énergétiques des ménages. D'autre part, les données de l'ADEME regroupant l'ensemble des Diagnostics de Performance Énergétique avec leurs caractéristiques techniques détaillées (surface, isolation, systèmes de chauffage, estimations théoriques selon la méthode 3CL). Enfin, les données géographiques de la Base Adresse Nationale (BAN) permettent d'enrichir l'analyse par des facteurs de localisation et d'exposition climatique spécifiques au territoire. Cette approche multi-sources présente des défis techniques considérables : fragmentation des données, formats hétérogènes, nécessité d'harmonisation et de croisement géospatial. Notre méthodologie data-driven propose une infrastructure d'intégration capable de normaliser ces flux disparates pour modéliser les gains financiers potentiels selon les caractéristiques spécifiques du bâti local et les habitudes de consommation réelles des ménages de l'Oise. Cette démarche s'inscrit dans une logique d'aide à la décision pour les propriétaires, en leur permettant d'arbitrer entre différents scénarios de rénovation sur la base de données factuelles et territorialisées, contribuant ainsi à accélérer la transition énergétique du parc résidentiel de l'Oise.

Dans ce document, une analyse des besoins sera réalisée en partant de la problématique posée par le persona (client fictif). Ensuite la méthode de collecte (vue dans le bloc 1 du rendu dédié à la stratégie de collecte) sera présentée brièvement. Un plan d'analyse sera présenté et implémenté ce qui permettra de visualiser les données et de répondre à la problématique. Pour finir, des recommandations seront données sur la base des résultats et appuyés par un support de formation pour la prise en main de l'outil dashboard développé.

A - Analyse des données

1 - Analyse du besoin

Contexte, enjeux et problématique

L'amélioration de la performance énergétique du parc immobilier constitue un enjeu majeur pour atteindre les objectifs de transition écologique et réduire la dépendance aux énergies fossiles. Dans ce contexte, le Diagnostic de Performance Énergétique (DPE) s'impose comme un outil de référence pour évaluer l'efficacité énergétique des logements et orienter les décisions de rénovation. Toutefois, plusieurs études ont mis en évidence un décalage significatif entre les estimations théoriques issues du DPE et les consommations réelles observées.

L'étude menée par le Conseil d'analyse économique (CAE), en collaboration avec Crédit Mutuel Alliance Fédérale, s'appuie sur un échantillon représentatif de 178 110 ménages français. Elle montre que si le DPE laisse à penser qu'un logement classé A ou B consomme environ six fois moins qu'un logement classé G, en réalité la différence n'est que d'environ 86 % (source batiweb, Annexe). D'autre part, le conseiller en rénovation Hello Watt montre, en utilisant les consommations réelles émises par leurs compteurs communicants, que pour un échantillon de 221 logements français, 71% d'entre eux n'ont pas la bonne étiquette DPE. Cette disparité trouve son origine dans deux mécanismes : d'une part, la surestimation théorique de la consommation par le modèle DPE (DPE mal établi) ; d'autre part, un effet rebond, selon lequel les ménages occupant un logement performant ont tendance à accroître leur confort (par exemple relever la température intérieure), tandis que ceux occupant des logements peu performants réduisent leur consommation par contrainte économique. Ainsi, la littérature existante met en évidence trois enjeux principaux liés au DPE : la transition énergétique, les économies d'énergie et la conformité réglementaire. En matière de transition énergétique, le DPE permet d'identifier les bâtiments qui consomment le plus d'énergie et d'encourager des travaux de rénovation pour réduire la consommation et les émissions de gaz à effet de serre. Les bénéfices induits se répercutent à l'échelle nationale. Une autre étude menée par Alexandre Bertran en mai 2024 a montré que, malgré une augmentation de 38 % de la demande de logements entre 1990 et 2020, la consommation énergétique annuelle moyenne de la France est restée stable depuis l'introduction du DPE.

Bien que le DPE soit réalisé par des professionnels certifiés et qu'il ait été révisé à trois reprises depuis 2010, notamment avec l'introduction de la méthode 3CL, il demeure limité par sa dépendance à des critères standardisés. Ces derniers ne reflètent pas toujours les comportements réels des occupants et peuvent réduire la précision des estimations. Face à ces limites et aux incitations gouvernementales à la rénovation, l'exploitation massive des données DPE apparaît nécessaire pour développer des indicateurs prédictifs plus précis et accompagner efficacement la transition énergétique.

Cadrage

C'est dans ce contexte que s'inscrit le challenge lancé par Enedis en partenariat avec l'Open Data University (ODU), intitulé : « Évaluer l'impact de la classe de DPE sur les consommations électriques de logements et confronter les estimations issues des DPE à des mesures réelles ». Ce projet vise à déterminer si les estimations fournies par le DPE correspondent aux consommations réelles mesurées et à estimer la proportion de la variance annuelle de consommation qui peut être expliquée par les caractéristiques des logements. Il s'attache également à évaluer les économies réalisables en améliorant la classe DPE.

Pour cette étude, le persona considéré comme client est un ménage résidant à Compiègne, dans l'Oise. L'objectif est d'estimer les économies potentielles issues de travaux de rénovation énergétique visant à améliorer la classe DPE, de valider la fiabilité des estimations officielles par comparaison avec des données réelles et de quantifier l'impact des comportements individuels sur la consommation.

Contraintes

Le calendrier défini dans le bloc 3 de gestion de projet prévoit une réalisation entre février et août 2025. Le volume de données à traiter est conséquent, estimé à environ 15 Go pour l'ensemble du territoire français, représentant plus de deux millions de lignes et environ deux cents colonnes. Dans le cadre universitaire de ce challenge, le coût de mise en place de la solution doit rester quasi nul, afin de permettre sa réutilisation par d'autres étudiants ou chercheurs.

Sur le plan technique, aucune source de données unique et complète ne permet actuellement de répondre à l'ensemble des besoins, ce qui impose de développer un système de collecte et d'intégration des données à partir de sources open data. Les API disponibles sont par ailleurs limitées par le flux maximal de données qu'il est possible d'en extraire. Pour contourner cette contrainte, il a été nécessaire de se former à l'interrogation des jeux de données par le biais d'ODSQL (Open Data SQL), ce qui a permis d'exploiter des volumes plus importants et de cibler finement les extractions. En ce qui concerne les données, les plus récentes dont nous disposons datent de 2023 car celles de 2024 ne sont pas bien formatées auprès de l'API Enedis (code département non renseignées à ce jour). Cependant, les données auprès des deux autres API sont à jour.

Enfin, du point de vue réglementaire, l'intégralité des données utilisées est issue de ressources ouvertes. Le projet a été développé en modules. Le module de collecte de données est diffusé en open source tandis que l'outil de dataviz est la propriété de l'équipe.

2 - Plan d'analyse

Afin de répondre à ces objectifs, l'analyse commencera par une phase de collecte et de nettoyage des données issues des sources Enedis, ADEME et BAN, suivie par la construction d'indicateurs clés tels que la consommation énergétique réelle moyenne, la classe DPE, et les caractéristiques techniques du logement. Des méthodes statistiques, d'analyse de variance et de modélisation supervisée sont utilisées pour évaluer la relation entre les variables du bâti et la consommation réelle. Le tableau suivant reprend en détail les étapes de ce plan :

Tableau 1 : Plan de nettoyage et d'analyse des données

Objectif	Etapes
Nettoyage des données, feature engineering, selection de variables	- Encodage, numérisation du jeu de données - Pipeline de data cleaning - o Supprimer les colonnes vides à plus de 90% - o Typer les variables - o Supprimer les variables dont l'entropie égale à 0 ou 1 - o Tests de corrélation et sélection de variables
Analyser l'écart moyen entre les estimations DPE et les consommations mesurées	- Calculer les indicateurs supplémentaires : - o Consommation en kwh/m2 habitable Enedis - o Différence entre consommation 5 usages finale estimée par le DPE et la consommation réelle Enedis Observée (kwh/m2) - Graphiques : - o Ecart moyen des consommations réelles Enedis vs théorique DPE par classe DPE - o Distribution des DPE par période de construction des logements - o Distribution des classes DPE - o Distribution des consommations d'électricité annuelle moyenne par adresse par logement - o Distribution des types d'énergie principale utilisés par classe DPE - Analyse par région climatique - Tests statistiques d'égalité des distributions dans 2 échantillons appariés (test t de Student ou Wilcoxon) - Régression linéaire sans variables de contrôle : <i>Consommations réelles</i> = $f(\text{Estimations DPE})$ et analyse du R^2 pour évaluer la capacité prédictive du DPE
Quantifier les gains liés à la rénovation énergétique	- Modèle de segmentation (arbres) avec les variables de contrôle sur les caractéristiques des logements - Calcul des gains théoriques basés sur l'évolution des estimations DPE à prix de kwh fixe donné par les APIs EDF

Au regard de ce plan, les livrables attendus et présentés le long du présent document sont les suivants :

- Rapport d'analyse statistique avec résultats détaillés et interprétations
- Tableau de bord interactif permettant l'exploration des résultats par segment
- Outil d'aide à la décision pour estimer les gains réels de rénovation
- Note méthodologique sur les limites et recommandations d'usage des résultats
- Guide de formation

3 - Requêtes et résultats de la collecte

La source de données utilisée est le jeu de données obtenu avec l'ETL développé. Elle contient les données sur les logements existants en France en 2023 avec les informations sur :

- Les consommations d'électricité par adresses fournis par Enedis
- Les adresses normalisées fournies par la BAN
- Les caractéristiques des logements fournies par l'ADEME dont les DPE

Les données ont été collectées avec le pipeline d'extraction développé par l'équipe et exécuté dans un notebook jupyter. Ceci a permis d'obtenir le jeu de données complet pour l'analyse. Pour rappels, nous avons présenté dans le bloc 1 le pipeline d'ETL développé par l'équipe pour ce projet. Il est composé de 3 sous-pipelines (Figure 14), dont le premier est nommé **DataEnedisAdemeExtractor**, destiné à la collecte des données depuis les 3 sources APIs. Nous en avons fait un package qu'il faut installer et importer et qui utilise certaines variables d'environnement (voir Figure 13 : Configuration ETL - variables d'environnement). Ce package se base sur des requêtes ODSQL (Open Data Soft Query Language) pour interroger les APIs sources avec les requêtes en concurrence (multi-threading). Les requêtes ODSQL utilisées sont présentées par l'image suivante.

```
1 # générer une url ODSQL pour requêter l'api enedis
2 self.get_url_enedis=lambda annee, code_departement, limit, offset: f"https://data.enedis.fr/api/explore/v2.1/catalog/datasets/consommation-annuelle-residentielle-par-adresse/records?where\
3                                     =annee=date('{annee}') and code_departement='{code_departement}'&order_by=tri_des_adresses&limit={limit}&offset={offset}"
4
5 # generer une url pour requeter l'api de la ban à partir d'une adresse
6 self.get_url_ademe_filter_on_ban = lambda key: f"https://data.ademe.fr/data-fair/api/v1/datasets/dpe03existant/lines?q_fields=identifiant_ban&q={key}" # update 19 juillet 2025
7 # generer une url pour requeter l'api de la ban à partir d'une adresse
8 self.get_url_ban_filter_on_adresse = lambda addr: f"https://data.geopf.fr/geocodage/search?q={addr}&limit=1" # adresse est complete car obtenue par concat dans enedis (update 23 juillet 2025)
```

Les endpoints des APIs de Enedis et de l'ADEME sont des API REST (protocole http) open source qui répondent en json. Pour Enedis, les requêtes sont limitées à 100 documents en une requête avec un système de pagination permettant d'obtenir jusqu'à 10 000 pour une même combinaison de filtres. Pour l'ADEME un utilisateur ne peut pas effectuer plus de 600 requêtes par intervalle de 60 secondes et la vitesse de téléchargement totale est limitée à 2 Mb/s. Les détails supplémentaires sur notre module de collecte sont présentés à nouveau dans la partie C - Support et accompagnement des utilisateurs.

Pour obtenir la base de données complète, nous avons exécuté la fonction de collecte en parallèle sur tous les départements de la France métropolitaine. Elle permet de collecter pour chaque département jusqu'à 10_000 adresses PDL Enedis. Ces adresses sont ensuite normalisées via la Base des Adresses national et couplées aux caractéristiques des logements de la base de l'ADEME. Pour chaque PDL Enedis, on a jusqu'à 1_000 logements associés.

```

1 import multiprocessing as mp
2 from dpe_enedis_ademe_etl_engine.pipelines import DataEnedisAdemeExtractor
3
4 codes_departements_metropole = [
5     "01", "02", "03", "04", "05", "06", "07", "08", "09", "10",
6     "11", "12", "13", "14", "15", "16", "17", "18", "19",
7     "21", "22", "23", "24", "25", "26", "27", "28",
8     "29", "30", "31", "32", "33", "34", "35", "36", "37", "38",
9     "39", "40", "41", "42", "43", "44", "45", "46", "47", "48",
10    "49", "50", "51", "52", "53", "54", "55", "56", "57", "58",
11    "59", "60", "61", "62", "63", "64", "65", "66", "67", "68",
12    "69", "70", "71", "72", "73", "74", "75", "76", "77", "78",
13    "79", "80", "81", "82", "83", "84", "85", "86", "87", "88",
14    "89", "90", "91", "92", "93", "94", "95"
15 ]
16
17 def run_pipeline(code_d):
18     tool = DataEnedisAdemeExtractor(debug=True)
19     try:
20         tool.extract(from_input=False, code_departement=int(code_d), annee=2023)
21         return f"Extraction complete -> departement {code_d}"
22     except Exception as e:
23         return f"Extraction ko -> departement {code_d}: {e}"
24
25 if __name__ == "__main__":
26     with mp.Pool(processes=mp.cpu_count()) as pool:
27         results = pool.map(run_pipeline, codes_departements_metropole)
28
29     for r in results:
30         print(r)

```

Figure 1: Importation et collecte des données complètes (silver data)

En termes de volume, le jeu de données complet extrait compte 220 colonnes et plus de 2 millions de lignes environs pour un total d'environ 4 Gb en mémoire (voir captures d'écran filestorage UI à la Figure 21). Pour l'analyse, en raison du volume des données, nous utilisons le framework Dask (basé sur le framework pandas) qui permet de distribuer le dataframe en mémoire. L'analyse est réalisée sur la plateforme google colab sur laquelle sont importées les données "silver" issues de l'extraction et de la jointure (données brutes complètes) stockées initialement dans le S3 (Figure 22).

Parmi les variables extraites nous disposons de la *consommation d'électricité annuelle moyenne par adresse par logement (en mwh)* et de la *surface habitable du logement*. A partir de ces variables, nous calculons les indicateurs suivants :

- Consommation d'électricité annuelle moyenne par logement par adresse en kwh

$$\text{consommation d'électricité en kwh} = 1\,000 * \text{consommation d'électricité en mwh}$$

- Consommation d'électricité en kwh/m2/an par logement : cet indicateur est calculé pour pouvoir comparer avec la consommation attendue donnée par le DPE elle-même exprimée en kwh/m2/an

$$\text{consommation d'électricité en kwh/m2/an} = \frac{\text{consommation d'électricité en kwh}}{\text{surface habitable logement ademe en m2}}$$

- Écart moyen absolu en kwh/m2/an entre les consommations réelles rapportées par Enedis et celles rapportées par le DPE

$$\text{écart} = \text{consommation d'électricité DPE en kwh/m2/an} - (\text{consommation d'électricité Enedis en kwh/m2/an})$$

- Distribution de ces écarts par classe énergétique
- Matrice gain énergétique potentiel moyen par saut de classe (G à F, F à E, etc.) : concrètement à partir d'un input de caractéristiques qui portent sur un logement, quelle consommation aurait-on obtenue si on avait une classe DPE différente.

Les quatre premiers indicateurs sont calculés et ajoutés au jeu de données pour la visualisation (dans le notebook et sur le dashboard). Le dernier indicateur est la matrice et elle est calculée après l'étape de modélisation.

	0	1	2	3	4
consommation_annuelle_moyenne_par_logement_de_l_adresse_mwh_enedis	1.0	2.0	1.0	2.0	1.0
consommation_annuelle_moyenne_par_logement_de_l_adresse_kwh_enedis	1256.0	1638.0	1269.0	1578.0	751.0
surface_habitable_logement_ademe	28.0	28.0	28.0	28.0	72.0
conso_kwh_m2	45.0	59.0	46.0	57.0	10.0
conso_5_usages_par_m2_ep_ademe	227.0	227.0	227.0	227.0	240.0
conso_5_usages_par_m2_ef_ademe	98.0	98.0	98.0	98.0	120.0
absolute_diff_conso_prim_fin	129.0	129.0	129.0	129.0	120.0
absolute_diff_conso_fin_act	53.0	39.0	52.0	41.0	109.0
consumption_difference	53.0	39.0	52.0	41.0	109.0

Figure 2 : Aperçu des indicateurs calculés

Conclusion partielle : Avec les indicateurs calculés, notamment les différences de consommation, on peut déjà voir qu'il y a un écart entre les consommations en kwh/m2 au niveau des logements (Figure 18 à Figure 20).

Une fois l'exploration des données faite dans le notebook jupyter sur colab avec le framework dask, le nettoyage est automatisé avec le pipeline **DataEnedisTransformer** et les résultats sont chargés sur un serveur postgres (voir captures en annexe). Des requêtes préparées sont ensuite utilisées pour alimenter le dashboard interactif. Les résultats de la data visualisation sont présentées dans la partie B - Visualisation des données et interprétation.

4 - Méthodologie de tests statistiques

Des tests statistiques de corrélation sont réalisés à l'étape de sélection de variables. En effet, chaque paire de variables est testée parmi les 220 variables que contient le jeu de données brut après la collecte. L'objectif est qu'entre deux variables, on garde uniquement celle qui est le plus corrélée à la variable target qui représente la *consommation annuelle moyenne par logement par adresse donnée par Enedis*. Cette méthode permet de réduire significativement le nombre de variables à considérer pour l'analyse dans la mesure où les variables qui ont des informations redondantes ne sont pas gardées. L'hypothèse nulle testée est la suivante :

- H_0 : Il n'y a pas de corrélation entre les variables testées. La statistique du test est significativement égale à 0.

Lorsque la p-valeur associée à cette statistique est supérieure au seuil de 5% fixé, les variables testées seront dites significativement corrélées avec un niveau de confiance de 95%.

De plus, pour la comparaison des consommations indiquées par le DPE et les consommations réelles, des tests statistiques d'égalité de la moyenne entre deux échantillons appariés sont réalisés. L'objectif est de tester si les consommations d'électricité moyenne par classe DPE sont statistiquement les égales entre les attendus DPE et les valeurs réelles en 2024 mesurées par Enedis. Le test t apparié évalue s'il existe une différence significative entre les moyennes de deux variables. Les échantillons correspondent aux logement ciblés par l'analyse (ici Paris en 2024). Les observations considérées sont d'une part les consommations d'électricité attendues fournies par le DPE et d'autre part les consommations d'électricité réelles fournies par Enedis. L'hypothèse nulle et l'hypothèse alternative sont formulées respectivement comme suit

- H_0 : Il n'y a pas de différence moyenne entre la consommation réelle et la consommation estimée par le DPE
- H_a : Il existe une différence significative entre la consommation réelle et estimée

Deux tests statistiques permettent de comparer les moyennes d'échantillons appariés :

- Approche paramétrique : test t de Student apparié
- Approche non-paramétrique : test de Wilcoxon

La différence principale étant que le test de Student suppose une distribution normale des différences, tandis que le test de Wilcoxon ne fait aucune hypothèse sur la distribution des données mais se base plutôt les rangs des observations.

En ce qui concerne l'interprétation, une p-valeur très petite associée à la statistique du test (inférieure à 0,05) indique qu'il existe une différence statistiquement significative entre les moyennes des deux valeurs de consommation pour cette catégorie DPE.

B - Visualisation des données et interprétation

1- Visualisation des données et interprétation

Le pipeline d'ETL a commencé l'exécution en ciblant le département de l'Oise (60). Ci-dessous une capture de la carte du dashboard (avec les départements 60, 75, 11, 13 et autres villes pour l'exemple). Les points rouges correspondent aux emplacements des points de livraison Enedis identifiés. Le tableau de droite présente le nombre de logements pour lesquels on dispose de données exploitables. Les adresses en elles-mêmes ne sont pas affichées.




Figure 3 : Carte de la France avec les points de livraison Enedis

A partir de cette carte, on peut zoomer sur une région en particulier. En ce qui concerne notre persona, la demande cible le département de l'Oise (voir figure suivante) et plus précisément la ville de Compiègne. On peut y voir les emplacements des PDL Enedis et on dénombre 2 848 logements dont le DPE a été communiqué à l'ADEME en 2023.




Figure 4 : PDL Enedis - ciblé sur le département de l'Oise (60) – DPE de la ville de Compiègne

Sur la figure suivante, on peut visualiser la distribution des DPE à gauche et la comparaison des consommations d'électricité réelles annuelles moyennes d'Enedis avec les consommations d'électricité théoriques données par le DPE à droite. D'une part les logements dans la ville de Compiègne sont classés de DPE B à G et la plupart sont C D ou E. D'autre part, le graphique en deux dimensions qui montre la consommation d'électricité mesurée par Enedis (en abscisse) vs celle donnée par le DPE (en ordonnée) montre qu'il n'y a pas un alignement entre ces deux valeurs et ceci est indépendant de la classe DPE du logement. La droite en pointillé représente la première bissectrice (droite $y=x$). En principe, les points (qui représentent les logements) devraient être plus ou moins alignés autour de cette droite pour que les consommations d'électricité Enedis réelles et DPE concordent. Nous pouvons remarquer que ce n'est pas le cas. Plus précisément, les logements classés G qui sont censés avoir des consommations d'électricité DPE supérieures à 300 kwh/m²/an ont en réalité pour la plupart les mêmes niveaux de consommations que les logements classés C D ou E.




Figure 5 : Graphiques lot 1 - DPE et comparaison des consommations d'électricité

Sur les graphiques suivants, on peut visualiser à gauche la distribution de la consommation annuelle moyenne d'électricité mesurée par Enedis et à droite la distribution de la différence de consommation (Enedis vs DPE) par étiquette DPE. On remarque sur le graphique de gauche que les box plots par étiquette DPE montrent bien que les consommations réelles médianes (trait du milieu) augmentent avec la classe DPE. Ce qui témoigne bien de l'affirmation suivante : plus la classe DPE est élevée, plus le logement consomme de l'électricité. Cependant, le graphique de droite révèle que plus la classe DPE est dégradée (vers G), plus l'écart entre consommation théorique et réelle s'accroît. Cette observation suggère deux hypothèses :

- D'une part le DPE pourrait surestimer la consommation des logements les moins performants
- D'autre part, il pourrait exister un effet comportemental où les occupants de logements mal classés adoptent spontanément des pratiques d'économie d'énergie plus strictes, réduisant ainsi leur consommation réelle par rapport aux prévisions théoriques.

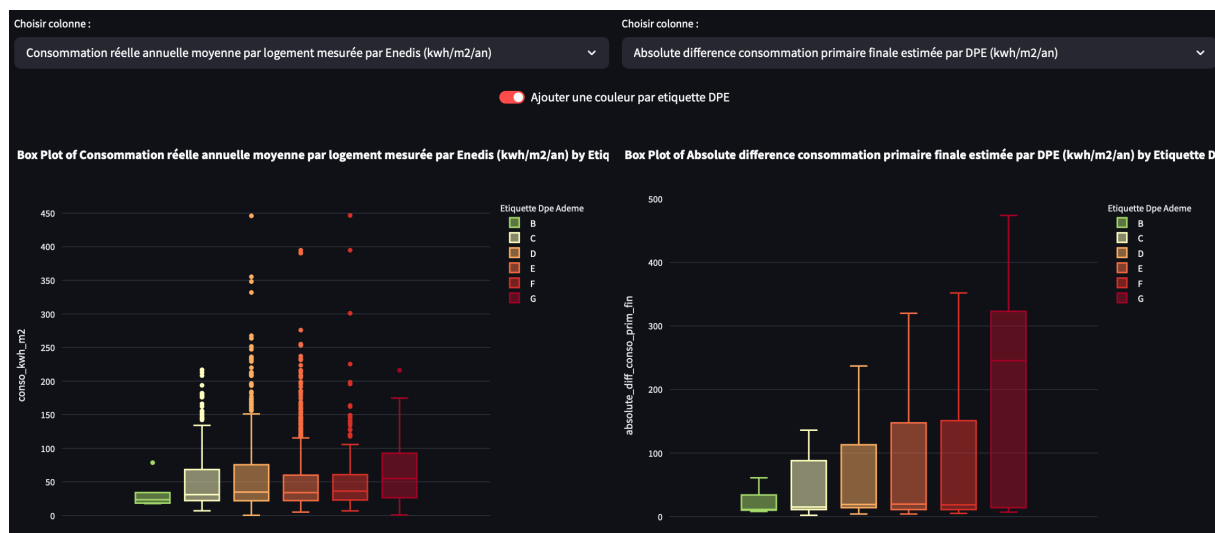


Figure 6 : Graphiques lot 2 - consommations d'électricité et différences par classe DPE

Les deux graphiques suivants montrent la distribution des périodes de construction des logements (à gauche) et la distribution du type d'énergie principale utilisée par les installations des logements.

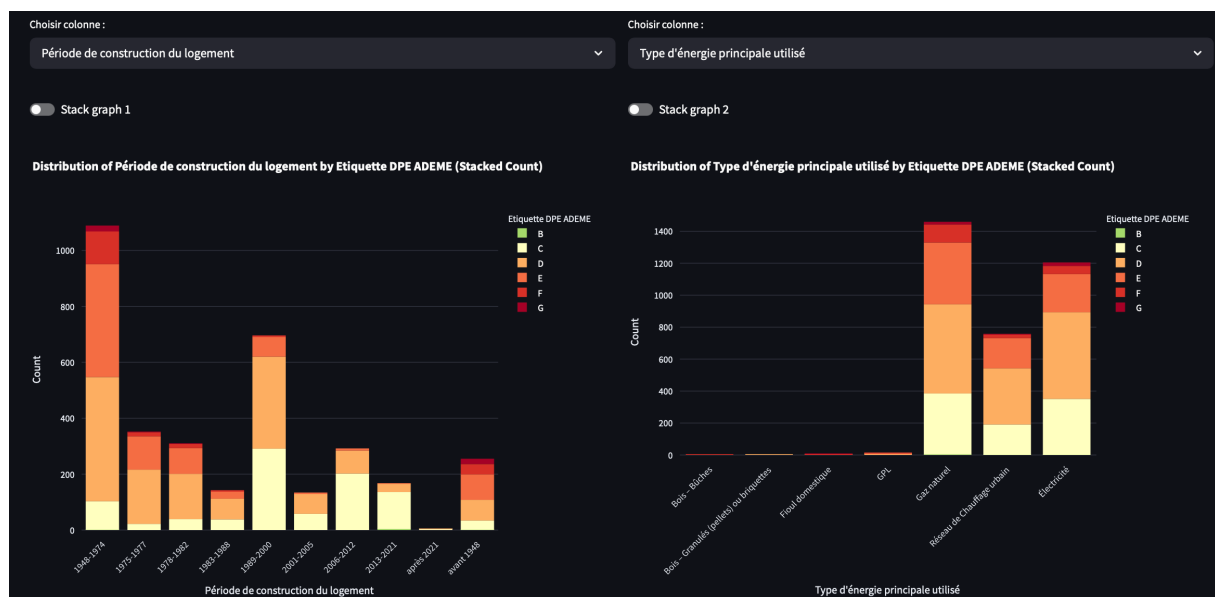


Figure 7 : Graphiques lot 3 - comparaisons absolues

Sur la figure de gauche, on peut voir que les logements de la ville de Compiègne ont pour la plupart été construits entre 1948 et 1974 d'une part et entre 1989 et 2000. La figure suivante permet de faire des comparaisons relatives grâce à l'option stack. Ainsi, on peut voir que la proportion de logements avec des DPE C (classe la plus basse dans la ville) augmente avec les périodes de constructions. Autrement dit, plus on avance dans le temps, plus les logements construits sont énergétiquement performants. Les logements avec DPE B ont été construits entre 2013 et 2021 et les derniers logements avec DPE G construits datent d'avant 1975.

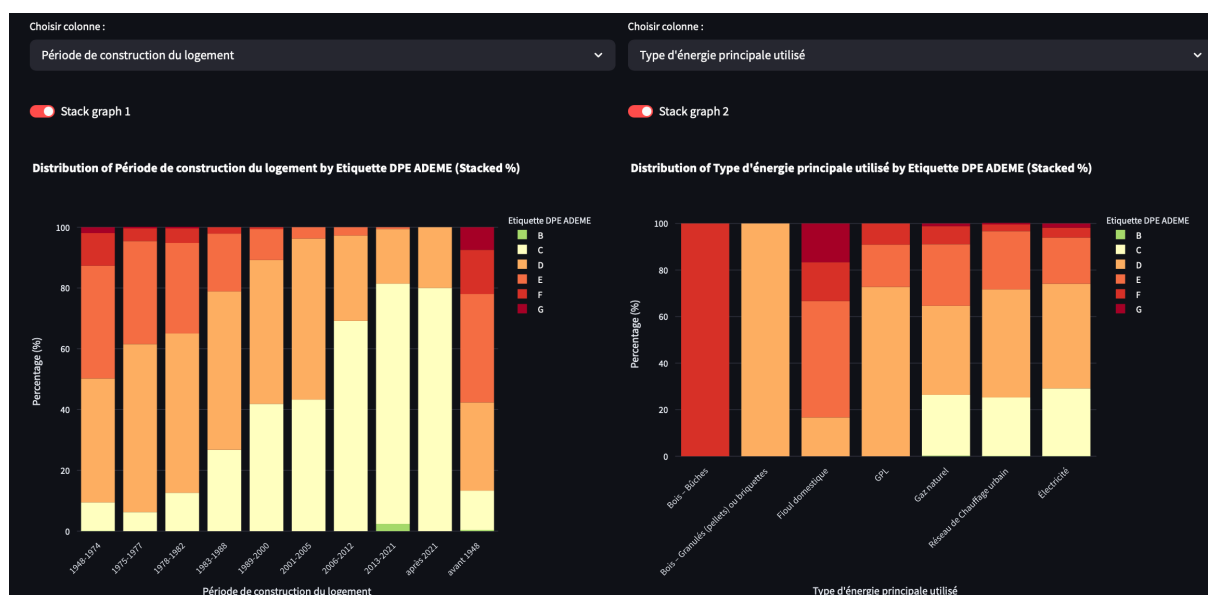


Figure 8 : Graphiques lot 3 - comparaisons relatives

Pour conclure sur le premier objectif d'évaluation de l'écart entre consommations réelles et théoriques, nous avons mené des tests statistiques comparant les distributions de consommation électrique entre les estimations DPE et les mesures Enedis. Les distributions comparées prennent en compte le périmètre du département de l'Oise (60) avec 15_333 logements. Les résultats du test par classe DPE sont présentés par le tableau below :

Statistical Test Results for Mean Consumption Difference by Etiquette DPE ADEME:						
Etiquette DPE ADEME	Sample Size	Paired t-test t-statistic	Paired t-test p-value	Wilcoxon statistic	Wilcoxon p-value	
0A	5	2.039	0.111	3.0	0.312	
1B	132	-3.754	0.000	2736.0	0.000	
2C	4799	-72.018	0.000	965815.0	0.000	
3D	6129	-80.302	0.000	1701179.0	0.000	
4E	3265	-81.039	0.000	146082.5	0.000	
5F	736	-48.104	0.000	2139.0	0.000	
6G	267	-28.780	0.000	92.0	0.000	

Figure 9 : Tests statistiques - comparaison de la moyenne de deux distributions appariées, département de l'Oise

Le tableau montre les résultats des tests t appariés et des tests de Wilcoxon des rangs signés comparant la moyenne de *conso_kwh_m2* (consommation réelle) et *conso_5_usages_m2_e_finale_ademe* (consommation estimée) pour chaque catégorie DPE (A à G). La colonne *Taille de l'échantillon* montre le nombre de logements dans chaque catégorie DPE pour lesquels les données de consommation réelle et estimée étaient disponibles. On peut voir que les catégories C, D, E ont des tailles d'échantillon relativement importantes, tandis que A et B en ont des significativement plus petites.

- Statistique t du test t apparié et valeur p :

Le test t apparié évalue s'il existe une différence significative entre les moyennes de deux mesures liées (dans ce cas, la consommation réelle vs estimée pour le même logement).

Une p-valeur très petite (inférieure à 0,05) indique qu'il existe une différence statistiquement significative entre les moyennes des deux valeurs de consommation pour cette catégorie DPE. Pour toutes les catégories B à G, les valeurs p sont extrêmement proches de 0 (affichées comme 0,000). Cela indique une différence significative entre la consommation réelle moyenne et la consommation estimée moyenne pour ces classes DPE. Pour la catégorie A, la valeur p (0,111) est supérieure au seuil, indiquant que nous n'avons pas assez de preuves pour rejeter l'hypothèse d'égalité des distributions (probablement à cause de la taille plus faible de l'échantillon).

Le signe de la statistique t indique la direction de la différence. Une statistique t positive suggère qu'en moyenne, la consommation réelle est plus élevée que la consommation estimée pour ce groupe. Une statistique t négative (comme pour les DPE B à G) suggère qu'en moyenne, la consommation réelle est plus faible que la consommation estimée pour ces groupes ce qui confirme les interprétations de la data visualisation.

- Statistique de Wilcoxon et valeur p :

Le test des rangs signés de Wilcoxon est une alternative non-paramétrique au test t apparié qui évalue s'il existe une différence significative dans les médianes (ou plus précisément, la distribution) de deux mesures liées. De la même manière que le test t, une valeur p très petite indique une différence statistiquement significative.

Pour toutes les catégories (B à G), les valeurs p du test de Wilcoxon sont également extrêmement petites (0,0000 ou très proches), renforçant la conclusion du test t qu'il existe des différences statistiquement significatives entre la consommation réelle et estimée pour chaque classe DPE.

En résumé, les résultats suggèrent fortement que pour chaque catégorie DPE, il existe une différence statistiquement significative entre la consommation réelle moyenne et la consommation estimée moyenne. En moyenne, pour les DPE B à G la consommation réelle est plus faible comparée aux valeurs estimées. Cela indique que l'estimation DPE surestime ou sous-estime systématiquement la consommation selon la classe de performance énergétique.

En ce qui concerne la simulation des gains d'économie réalisables en engageant des travaux de rénovation, nous avons réalisé une modélisation. L'objectif de la modélisation est d'obtenir un estimateur de la consommation réelle en kwh/m2 pour les logements à partir des 220 caractéristiques présentes dans le jeu de données nettoyé portant sur tout le département de l'Oise en 2023 (15 000 logements environs).

Pour ce faire, nous avons mis en place une méthodologie d'encodage des données avec des categorical encoders du framework scikit-learn. Des modèles de régression linéaires et des modèles à segmentation (modèles d'arbres) ont été testés, avec comme métrique de performance le R2 (part de la variabilité de la variable cible expliquée). Il en ressort que les modèles de régression captent mal la structure du jeu de données et que les modèles d'arbres sont plus performants pour notre cas d'étude (voir annexe Figure 17).

Ainsi, le modèle le plus performant obtenu après validation croisée et optimisation des hyperparamètres est un modèle de random forest. Ce modèle nous a accessoirement permi

de faire de la sélection de variables parmi les 220 variables initialement présentes dans le jeu de données. Ainsi après ces itérations, nous avons pu obtenir un modèle proxy qui se base sur une dizaine de variables pour estimer la consommation d'électricité réelle en kwh/m2. Ce modèle requiert en input les variables présentées sur le graphique suivant à droite. Les courbes d'apprentissage du modèle avec la mérique du R2 sont représentées par le graphique de droite.




Figure 10 : Courbes d'apprentissage et Importance des variables dans le modèle

Ce modèle obtenu se trompe en moyenne 18% (Mean Average Percentage Error) du temps et il se trompe d'environ 26 kwh/m2 (Mean Squared Error). Il explique 86% de la variabilité de la consommation électrique en kwh/m2 des logements dans le département de l'Oise en France en 2023. Le reste de la variabilité est imputable aux facteurs non présents dans le jeu de données (données climatiques, habitudes des ménages etc..).

Besoin ECS annuel total du logement (kWh)
 0.00 | 100.00 | 800.00 | 17.00

Emission GES ECS totale (kgCO2/an)
 0.00 | 5.00 | 17.00 | 25.43

Emission GES totale 5 usages rapportée à la surface m2 (kgCO2/an)
 0.00 | 5.00 | 17.00 | 25.43

Coeff. de déperdition thermique du bâtiment (W/m2/Kelvin)
 0.00 | 1.00 | 17.00 | 25.43

Emission GES du chauffage totale (kgCO2/an)
 0.00 | 5.00 | 17.00 | 25.43

Surface habitable du logement
 0.00 | 50.00 | 1000.00

Etiquette GES
 D

Etiquette DPE
 E

Période de construction du logement
 avant 1948

Type d'énergie principale consommée par les installations du logement
 Électricité

Type d'énergie principale pour le chauffage
 Gaz naturel

Type d'énergie principale consommée pour les besoins ECS
 Gaz naturel

Figure 11 : Exemple d'inputs pour le modèle - étude de cas

Sur la base de ce modèle intégré au serveur API, une page d'Estimation a été ajoutée au dashboard. Sur la base des inputs que l'utilisateur renseigne, nous sommes en mesure de donner une approximation des gains réalisables toutes choses égales par ailleurs en changeant de classe DPE (matrice des gains).

Détails prédictions

- Montant euros/an = prix du kwh (euros/an) x consommation kwh/an
- Economie euros/an = Economie réalisée en changeant vers la classe DPE au dessus
- Economie cumulée euros/an = Economie réalisée en changeant de plusieurs classes DPE au dessus

Etiquette DPE	Conso kwh/m2/an	Conso kwh/an	Montant (euros/an)	Economies (euros/an) vs classe DPE précédente	Economies cumulées (euros/an)
A	263.29	13,164.35	2,653.93 €	0.00 €	165.96 €
B	263.29	13,164.35	2,653.93 €	0.00 €	165.96 €
C	263.29	13,164.35	2,653.93 €	0.00 €	165.96 €
D	263.29	13,164.35	2,653.93 €	87.76 €	165.96 €
E	271.99	13,599.65	2,741.69 €	78.20 €	78.20 €
F	279.75	13,987.55	2,819.89 €	0.00 €	0.00 €
G	279.75	13,987.55	2,819.89 €	None	None

Reset all

Figure 12 : Résultat simulation gains après rénovation énergétique – étude de cas

Une simulation avec les inputs de la Figure 11 permet d’obtenir les résultats above. En résumé pour un logement ayant ces caractéristiques avec un DPE E, si les propriétaires engagent des travaux de rénovation toutes choses égales par ailleurs, il économiseraient environs 87 € par an en changeant de classe DPE à la hausse (E vers D ou E vers B etc..).

2- Recommandations

À l’issue des analyses et des modélisations effectuées, nous pouvons préconiser les actions suivantes pour répondre aux besoins de notre persona :

- Sujet : valider la fiabilité des DPE avec les données réelles de consommation

Le ménage a besoin d’une évaluation fiable et précise de sa consommation énergétique pour orienter ses décisions de rénovation. La première recommandation au regard de ce besoin est de prioriser l’utilisation de l’historique des données de consommation réelles fournies par Enedis pour évaluer la performance énergétique du logement. Nous faisons cette recommandation car l’analyse a démontré un écart significatif entre les consommations théoriques issues du DPE et les consommations réelles mesurées par Enedis, notamment pour les logements des classes D à G. Ce décalage peut induire des décisions erronées si elles reposent exclusivement sur le DPE.

- Sujet : quantifier l’impact des habitudes du quotidien sur la consommation électrique mesurée

Pour améliorer les économies d’énergie, le ménage doit comprendre non seulement les caractéristiques physiques du logement, mais aussi l’influence de ses pratiques quotidiennes. Nos résultats ont montré que les écarts entre consommation réelle et consommation estimée par le DPE peuvent être dus en grande partie à des comportements d’économie d’énergie adoptés par les occupants, particulièrement dans les logements à faible performance énergétique. Cependant, puisque nous ne disposons pas de données modélisant les habitudes de consommation quotidiennes des personnes, ni le taux d’occupation des logements, il faut préciser cette recommandation est faite toutes choses égales par ailleurs. En effet, les caractéristiques

des logements expliquent en moyenne 86% de la consommation d'électricité réelle dans le modèle mais les 14% restants sont imputables à plusieurs facteurs (météo, habitudes etc.).

- Sujet : estimer les économies potentielles issues de travaux de rénovation énergétique visant à améliorer la classe DPE

Le ménage doit pouvoir estimer de manière fiable les économies énergétiques et financières potentielles avant d'investir dans des travaux. A cet effet, le modèle de développé, qui explique 86 % de la variabilité de la consommation réelle, permet de simuler l'impact des changements de classe DPE en fonction des caractéristiques précises du logement. Cependant comme le montre la Figure 10 : Courbes d'apprentissage et Importance des variables dans le modèle, l'étiquette DPE en elle même n'est pas très importante pour prédire la consommation d'électricité. Il faudrait plutôt faire des travaux de rénovation pour réduire les besoins en Eau Chaude Sanitaires (en kwh) et la réduction des émissions GES du logement, le type d'énergie principale utilisée par le logement etc.

C - Support et accompagnement des utilisateurs

1 - Support de formation

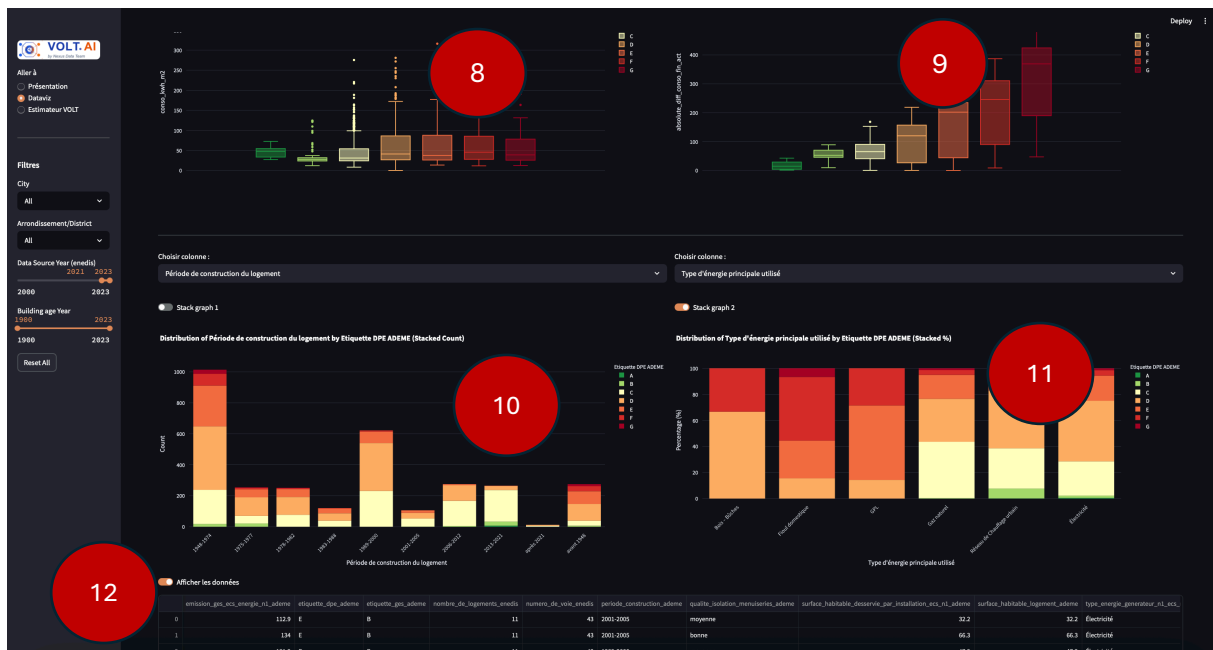
- Prise en main de l'outil de visualisation

Les captures d'écran suivantes présentent l'outil de data visualisation développé. Leur description constitue un guide pratique pour la prise en main du dashboard.

Pour commencer, il faut s'identifier. Cette étape permet de faire la différence entre un utilisateur client qui a les droits de lecture seul sur la base de données et l'utilisateur admin. La page de connexion décrit le contexte, la problématique et le but de l'outil de visualisation. Rien n'est visible tant que l'utilisateur ne s'est pas identifié avec une adresse mail. Sur ladite adresse, il reçoit un code One Time Password (OTP) à 5 chiffres à saisir pour finir sa connexion. L'adresse mail nous sert à partager plus tard le présent support de formation, les évolutions futures et mises à jour etc. Nous n'enregistrons pas de mot de passe, la session se termine dès que l'utilisateur se déconnecte ou quitte la page.



En (5) et (6) on retrouve des graphiques qui présentent la distribution des DPE d'une part et la comparaison des consommations d'électricité réelles Enedis avec celles des DPE par classe DPE d'autre part. Tous les graphiques ont été interprété dans la partie dédiée à l'analyse.




Pour finir cette page, en (8), (9), (10) et (11) on retrouve un autre lot de graphique avec représentation dynamique. L'utilisateur peut choisir la variable à représenter avec le menu déroulant. De plus il peut soit visualiser les distribution en l'état ou alors afficher les représentations empilées (une barre représente 100%) pour faire des comparaisons relatives (voir 11 par exemple). Ces graphiques ont également été interprétés dans la partie dédiée à la data visualisation. Et les données qui ont servi de source pour ces représentations sont présentes en (12) et disponibles pour être téléchargées. Nous n'exposons pas d'adresses.

La page Estimateur VOLT présente l'outil de simulation développé.

En (11) l'utilisateur retrouve une option qui lui permet de choisir s'il souhaite que les données qu'il entre pour les estimations soient enregistrée sur nos serveurs pour servir à monitorer le drift du modèle. Avec la barre de recherche (12) il peut saisir une adresse (la sienne en principe) et le serveur fournira les données déjà pré-remplies pour le formulaire. Sinon, il devra saisir les données lui-même. Le formulaire (13) est constitué des variables inputs du modèle. Les labels ont été revus pour apporter plus de contexte.

Une fois le formulaire rempli, l'utilisateur peut lancer les estimations avec le bouton (15). Le résultat envoyé par le serveur contient les détails de la prédiction. La manière dont la matrice est calculé est détaillée dans la documentation technique (rubrique suivante). Le résultat contient des informations sur l'étiquette DPE de la saisie, les consommations attendues (du DPE avec la méthode 3CL actuelle), la consommation réelle estimée par notre modèle sur la base des entrées de l'utilisateur. Ces deux consommations sont

exprimées en kwh/m2/an. Ensuite nous affichons la consommation annuelle moyenne estimée et nous calculons le coût avec un tarif dont les méta données sont présentées en (16). Enfin la matrice des gains est présentée en (17).



- Serveur API

Le serveur API a été développé avec le framework FastAPI. Les routes exposées sont présentées par l'image suivante et la documentation du serveur est disponible sur le swagger ou le readme file du repos github [DPE-Energy-Performance-Analysis-API](#).

DPE-API 0.0.1 OAS 3.1
/openapi.json
API backend for DPE Energy Performance Analysis


Authorize

Method	Endpoint	Description	Auth
GET	/	Start	
GET	/health	Health Check	
GET	/price_kwh	Get Kwh Price	
GET	/user-reader	Get User Reader	🔒
GET	/user-admin	Get User Admin	🔒
GET	/db	Init Db	🔒
GET	/db/reader/adresses/getall	Get All Adresses	🔒
GET	/db/reader/adresses/searchadress/{searched}	Search Adresses	🔒
GET	/db/reader/adresses/getone/{searched_adress}	Search Adresses	🔒
GET	/db/reader/adresses/cities	Get Cities Names And Codes	🔒
GET	/db/reader/adresses/{city_name}/allcoords	Get Coord By City Name	🔒
GET	/db/reader/logements/getall	Get All Logements	🔒


- Module de collecte des données ETL

La plupart des données dont les utilisateurs ont besoin sont disponibles au niveau de l'outil de visualisation (12). Cependant, pour un utilisateur qui souhaite reprendre l'étude depuis la source des données, nous exposons le module de collecte de données via un package ETL disponible ici en open source : [DPE-Energy-Performance-Analysis-ETL](#). La documentation sur l'utilisation et la conception de ce module de collecte de données et les traitements effectués ont été présentés dans le bloc 1 des rendus du titre RNCP.

Par ailleurs, une fois le serveur démarré, un utilisateur de niveau administrateur (authentifié) peut exécuter le déploiement de l'ETL. Ce faisant l'ETL s'exécutera à la fréquence planifiée et les données seront mises à jour périodiquement de manière automatique. La route à utiliser au niveau de l'API est la suivante : *etl/start-deployment*



Le statut du déploiement est alors visible sur l'UI du serveur prefect : <http://localhost:4200/>



2 - Documentation technique

Les objectifs de cette documentation technique sont :

- **Compréhension** : tout lecteur peut comprendre quelles données ont été utilisées, comment elles ont été traitées et quels indicateurs sont produits.
- **Transmission** : l'équipe projet, le client et les nouveaux utilisateurs peuvent reprendre et maintenir l'outil.
- **Reproductibilité** : tout chercheur disposant des mêmes données et scripts peut reproduire les résultats.

Ce document s'adresse :

- Au client demandeur (notre persona qui est un ménage fictif habitant le département de l'Oise 60)

- Aux utilisateurs finaux (analystes, data scientists, spécialistes du DPE et du secteur de la rénovation énergétique) souhaitant exploiter l'outil pour effectuer des analyses
- Administrateurs (data engineers de l'équipe) chargés de déployer, configurer et maintenir le système
- Développeurs amenés à intégrer ou faire évoluer les fonctionnalités de l'outil.

Les données considérées pour développer cet outil de visualisation et d'estimation :

- **Origine** : Données de consommations d'électricité et caractéristiques des logements fournies par les API de bases publiques de l'ADEME (mise à jour chaque semaine), de la BAN et d'Enedis (mis à jour annuellement)
- **Données de tarification utilisées** : Tarifs de l'électricité EDF collectés via open-dpe.fr
- **Périmètre** : données limitées à la France métropolitaine et sur le département de l'Oise (60) pour nos interprétations dans le rapport d'étude. La période d'analyse est l'année 2023 mais la collecte peut être reproduite sur les années antérieures.
- **Variables principales** : Caractéristiques des bâtiments (année de construction, surface, type d'isolation, mode de chauffage) - Classe DPE et consommation énergétique estimée - Consommation électrique réelle (kWh/an)

Les étapes de nettoyage des données brutes sont listées ici et présentées plus en détail dans le bloc 1 des rendus du titre RNCP et sur le repos github de l'ETL ([DPE-Energy-Performance-Analysis-ETL](#)). Il s'agit du :

Nettoyage

- Suppression des doublons, variables à entropie nulle ou égale à 1 et suppression des enregistrements incomplets
- Normalisation des unités (kWh, m²)
- Encodage des variables catégorielles (type de chauffage, isolation, etc.)

Calculs statistiques

- Moyenne et médiane des consommations par classe DPE
- Corrélations entre consommation réelle et estimation DPE
- Test d'égalité de la moyenne de deux distributions appariées (t test et wilcoxon).

Modélisation

- Régression linéaire pour estimer la consommation en fonction des caractéristiques.
- Random Forest pour évaluer l'importance relative de chaque facteur explicatif.

Comparaison théorique vs réelle

- Calcul du Δ consommation = consommation d'électricité réelle – estimation DPE
- Analyse de la part de variance expliquée par les caractéristiques techniques vs comportements d'usage.

Les formules de calcul d'indicateurs ont été présentées au début de ce document et sont décrites ici sous forme de tableau :

Indicateur	Définition	Unité	Méthode de calcul	Utilité
Consommation moyenne par classe DPE	Moyenne des consommations réelles des logements dans chaque classe DPE	kWh/m2	Moyenne par classe	Évaluer la précision des DPE
Delta conso (réel - estimé)	Différence entre consommation réelle et estimation DPE	kWh/m2	Conso_réelle - Conso_estimée par classe DPE	Identifier l'écart de performance
Gain estimé par changement de classe DPE	Réduction moyenne de consommation si amélioration d'une classe	% et kWh/an	Différence moyenne entre classes adjacentes	Aider à la décision pour rénovation
Impact des habitudes et autres facteurs non modélisés	Part de variance expliquée par les variables comportementales	% du R2 non expliqué par le modèle (variabilité de la consommation réelle en kwh/m2)	Modélisation statistique	Comprendre l'influence de l'usage

Le système d'analyse de données est constitué d'un serveur API et d'un outil de datavisualisation qui requête le serveur API. Tous les calculs se font dans le serveur qui livre les indicateurs prêts à être représenté graphiquement. L'outil de visualisation est conçu pour :

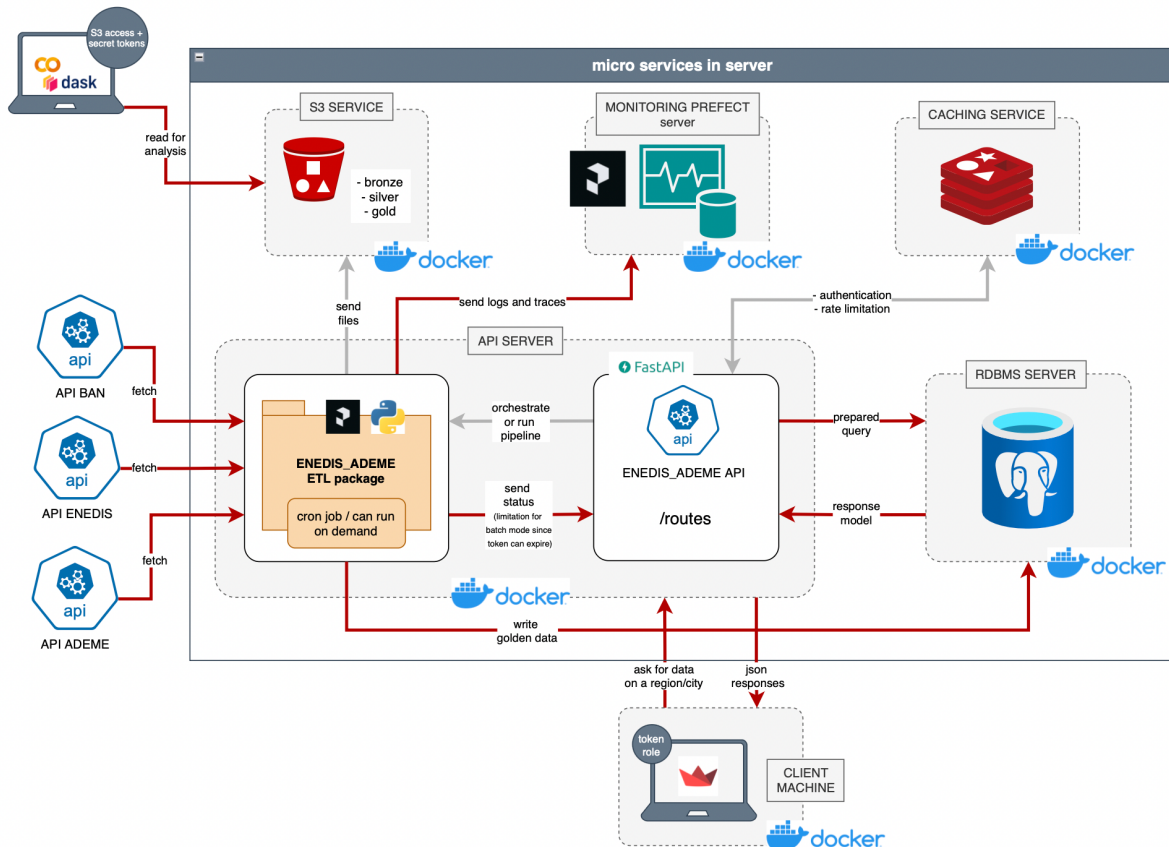
- Calculer les indicateurs cités et afficher des graphiques portant sur les consommations d'électricité, les caractéristiques des logements y compris les étiquettes DPE
- Effectuer des traitements statistiques et des modélisations prédictives de la consommation d'électricité en kwh/m2/an des logements de type résidentiels à partir d'un ensemble d'inputs définis.
- Restituer les résultats sous forme de tableaux de bord interactifs et rapports exportables.
- Collecter des données depuis différentes sources (API Enedis, API BAN, API ADEME).
- Assurer la traçabilité complète du processus d'analyse (logs, versionning du pipeline d'ETL, des données et du modèle).

Les technologies constituant le système d'information complet sont listées ci-dessous :

- Language : Python 3.12
- Serveur API REST : Framework FastAPI, Pydantic et Uvicorn
- Authentification : OAuth2
- Orchestrateur ETL : Prefect Flow

- Data processing : Dask (calcul distribué), Pandas, NumPy, Scipy et Scikit-learn
- Stockage : PostgreSQL, parquet, S3/MinIO, Redis
- Outil de visualisation : Streamlit, Plotly
- Déploiement : Docker + CI/CD (Github Actions)

Schéma simplifié



Pré-requis installation via docker (plus pratique)

- **Environnement** : Python 3.12, Docker, accès réseau à la base de données (remote ou localhost)
- **Accès** : Compte utilisateur validé + droits selon profil (reader, admin)
- **Données** : Formats supportés pour les fichiers de données : CSV, JSON, PARQUET.

Pour l'installation récupérez les images docker sur dockerhub :

- Serveur : [dockerhub-dpe-energy-performance-analysis-api](#) (latest)
- Outil de dashboard : [dockerhub-dpe-energy-performance-analysis-clientapp](#) (latest)
- Image MinIO S3 (tag latest, version 9.5)
- Image Redis (tag 7-alpine)
- Image Postgres server (tag latest, version 17.4)

Un exemple de fichier de configuration avec docker compose est disponible sur le repos github : [DPE-Energy-Performance-Analysis](#).

Pour la configuration, définissez les variables d'environnement suivantes respectivement pour le conteneur client et le conteneur du serveur. Le client dépend du services S3 et du serveur API. Le serveur API dépend de POSTGRES, du S3, de Redis, de la config SMTP (pour l'envoi des mails) et de Prefect.

```
"ENV": "LOCAL",
"API_HOST": "xxxxxx",
"API_PORT": "8000",

"REDIS_HOST": "xxxxxxx",
"REDIS_PORT": "6379",

"SMTP_SERVER": "smtp.domain.com",
"SMTP_PORT": "465",
"SMTP_USERNAME": "xxxxxxx@domain.com",
"SMTP_PASSWORD": "xxxxxxx",
"ADMIN_EMAIL": "admin@domain.com",

"POSTGRES_HOST": "localhost",
"POSTGRES_PORT": "5432",
"POSTGRES_DB_NAME": "dpedb_v2",
"POSTGRES_ADMIN_USERNAME": "postgres",
"POSTGRES_ADMIN_PASSWORD": "xxxxxxx",
"POSTGRES_READER_USERNAME": "reader",
"POSTGRES_READER_PASSWORD": "xxxxxxx",
"POSTGRES_WRITER_USERNAME": "writer",
"POSTGRES_WRITER_PASSWORD": "xxxxxxx",

"S3_ACCESS_KEY": "xxxxxxx",
"S3_SECRET_KEY": "xxxxxxx",
"S3_BUCKET_NAME": "dpe-storage-v1",
"S3_REGION": "eu-west",
"S3_ENDPOINT_URL": "host:port",

PREFECT_API_URL="http://prefect:4200/api"

"PATH_LOG_DIR" : "etl/logs/",
"PATH_ARCHIVE_DIR" : "etl/data/archive/",
"PATH_DATA_BRONZE" : "etl/data/1_bronze/",
"PATH_DATA_SILVER" : "etl/data/2_silver/",
"PATH_DATA_GOLD" : "etl/data/3_gold/",
"PATH_FILE_INPUT_ENEDIS_CSV": "etl/data/1_bronze/conso_enedis.csv",
"SCHEMA_ETL_INPUT_FILEPATH": "config/schema_input_data.json",
"SCHEMA_SILVER_DATA_FILEPATH": "etl/ressources/schemas/schema_silver_data.json",
"SCHEMA_GOLDEN_DATA_FILEPATH": "config/schema_golden_data.json"
```

Figure 13 : Configuration ETL - variables d'environnement

Installation via Docker compose (recommandé)

La config docker compose est disponible ici : [Projet-DPE-Energy-Performance-Analysis](#)

L'utilisation de l'interface web a été présenté étape par étape dans la rubrique précédente de ce rapport ([1 - Support de formation](#)). Il faut :

1. Ouvrir le navigateur et aller sur <http://localhost:8501>(url)
2. Faire une demande d'authentification
3. Configurer les paramètres d'analyse (filtres, période, métriques)
4. Lancer l'analyse (le guide est disponible dans la section précédente de ce rapport)
5. Consulter les graphiques et exporter le rapport si besoin.

Pour utiliser directement le serveur API :

- vérifier que les services sont connectés
- exécuter un run de l'ETL ou commencez le déploiement de l'ETL avec la route dédiée
- s'authentifier (email + otp) et enregistrer le cookie de connexion
- requêter l'endpoint de données sur les logements

La tracabilité des workflows data est gérée par l'orchestrateur Prefect dont le serveur est accessible via le serveur API avec la route : `<url_serveur_Api>/etl/monitoring`

- **Logs** : redirection de l'api vers le serveur prefect
- **Versioning des données** : Les datasets bruts et traités sont conservés avec un identifiant unique.
- **Historique des analyses** : Consultable depuis l'interface ou via l'API.

Enfin pour le support et maintenance ou pour la contribution au projet, vous pouvez retrouver le projet sur github en Open source ici : [Projet-DPE-Energy-Performance-Analysis](#)

- **Bugs / anomalies** : Ouvrir un ticket sur le dépôt github.
- **Mises à jour** : Chaque release est documentée avec un changelog et une release note.
- **Contacts** : fereolynovdpe@gmail.com

Conclusion

L'étude menée met en évidence que, si les estimations issues des Diagnostics de Performance Énergétique (DPE) constituent un repère utile, elles présentent des écarts significatifs avec les consommations réelles mesurées. Ces écarts s'expliquent à la fois par des facteurs techniques liés aux caractéristiques des bâtiments (isolation, mode de chauffage, année de construction) et par des facteurs comportementaux (habitudes de consommation, taux d'occupation).

Le système d'information développé permet non seulement d'objectiver ces différences, de les observer par ville et par département mais aussi de modéliser et de quantifier l'impact potentiel d'une amélioration de la classe DPE sur la consommation énergétique. Cette approche facilite la prise de décision, tant pour les acteurs publics dans le cadre des politiques de transition énergétique que pour les particuliers souhaitant optimiser leur consommation.

Ceci vient confirmer les études existantes sur ce sujet et permet de reproduire les résultats et des analyses plus complexes avec la mise à disposition du pipeline ETL de collecte des données complètes. En fournissant une traçabilité complète des sources de données, des méthodes de calcul et des indicateurs, le système garantit la reproductibilité de l'analyse. Les résultats obtenus constituent une base solide pour affiner les modèles de prévision et orienter les investissements en rénovation énergétique vers les leviers les plus efficaces.

Annexe

Documentation - Dépôts github du projet et git modules

- [DPE-Energy-Performance-Analysis](#)
- [Submodule DPE-Energy-Performance-Analysis-API](#)
- [Submodule DPE-Energy-Performance-Analysis-ETL](#)
- [Submodule DPE-Energy-Performance-Analysis-ClientApp](#)

Sources, articles et études similaires existantes

- Origine du projet : <https://defis.data.gouv.fr/defis/diagnostics-de-performance-energetique>
- https://cdn.hellowatt.fr/media/model_files/Validation_des_DPE_via_la_consommation_mesuree_par_les_compteurs_connectes.pdf, Validation à grande échelle des diagnostics de performance énergétique via la consommation mesurée par les compteurs connectés, Guillaume Matheron (hello watt), 2023
- <https://www.bailfacile.fr/guides/dpe-energie-primaire-ou-finale>, article web de Stéphanie Comitogianni (Economiste de la construction), 2024
- <https://www.batiweb.com/actualites/immobilier/logement-pres-de-3-dpe-sur-4-seraient-incorrects-hello-watt-41548>, article web de Virginie Kroun (hello watt)
- Alexandre Betran, Evaluation l'impact du Diagnostic de Performance Energétique (DPE) sur les consommations énergétiques des logements., 2024
- Dataactivist, DPE vs consommation réelle : opacité sur les performances réelles du bâti public à Compiègne., Juillet 2024
- Diogo Christopher & al., Evaluer l'impact de la classe de Diagnostic de Performance Energétique (DPE) sur les consommations électriques de logements et confronter les estimations issues des DPE à des mesures réelles : Charente Maritime., Mai 2024
- Greenwave, Dashboard avec des métriques sur les DPE dans la ville de Paris. , Juillet 2024
- Walmsley, Menard, Picard & al., Impact des Diagnostics de Performance Énergétique (DPE)., EISGI La Rochelle, Avril 2024

Figures

☐	ETL data extraction pipeline > stoic-vulture
☒	Completed 2025/08/02 01:39:21 PM 8 Parameters 5s 7 Task runs
☐	ETL data loading pipeline > quirky-stallion
☒	Completed 2025/08/01 03:43:35 PM 1 Parameter 1s 6 Task runs
☐	ETL data transformation pipeline > gorgeous-pudu
☒	Completed 2025/08/01 03:43:35 PM 3 Parameters 1s 9 Task runs

Figure 14 : Pipelines d'ETL




Figure 15 : Schéma de la base de données

GET	/price_kwh	Get Kwh Price
auth		
POST	/send-otp	Send Otp
POST	/login-with-otp	Login With Otp
GET	/user-status	Get User
database		
GET	/db	Init Db Require Admin Level Access
GET	/db/reader/adresses/getall	Get All Adresses Require Admin Level Access
GET	/db/reader/adresses/searchadresses/{searched}	Search Similar Adresses Require Reader Level Access
GET	/db/reader/adresses/getone/{searched_adresse}	Get One Adresses Require Reader Level Access
GET	/db/reader/adresses/cities	Get Cities Names And Codes Reader Level
GET	/db/reader/adresses/{city_name}/allcoords	Get Coord By City Name Reader Level
GET	/db/reader/logements/getall	Get All Logements Reader Level
GET	/db/reader/logements/getbyadress/{searched}	Get Logements By Adress Reader Level
GET	/db/reader/logements/getonebycity/{city_name}	Get One Logements By City Name
GET	/db/reader/logements/getallbycity/{city_name}	Get All Logements By City Name
GET	/model/{version}/config	Get Model Config
POST	/model/v1/predict	Predict

Figure 16 : Routes avec les requêtes préparées pour le dashboard client




Figure 17 : Comparaisons résultats modèles de régression

```

enedis_ademe_var_selection
File Edit View Insert Runtime Tools Help

Commands + Code + Text Run all

PLAN
• Graphique en 2 dimensions pour comparer les consommations réelles et théoriques
• Calcul des écarts absolus et relatifs par classe énergétique
• Analyse par région climatique
• Tests statistiques d'égalité de la moyenne (test t de Student ou test de Wilcoxon)
• Régression linéaire sans variables de contrôle : Consommations réelles = f(Estimations DPE) et analyse du R² pour évaluer la capacité prédictive du DPE
• Modèle de segmentation avec les variables de contrôle sur les caractéristiques des logements
• Validation de la robustesse des clusters

ANALYSE
▼ Feature engineering

from google.colab import drive
drive.mount('/content/drive/')

Mounted at /content/drive/

[ ] pip install category_encoders unidecode

Show hidden output

▼ 1 - Load data and describe

import pandas as pd
import pickle, sklearn
import category_encoders as ce
from sklearn.compose import ColumnTransformer
  
```

Figure 18 : Analyse exploratoire sur colab – 1

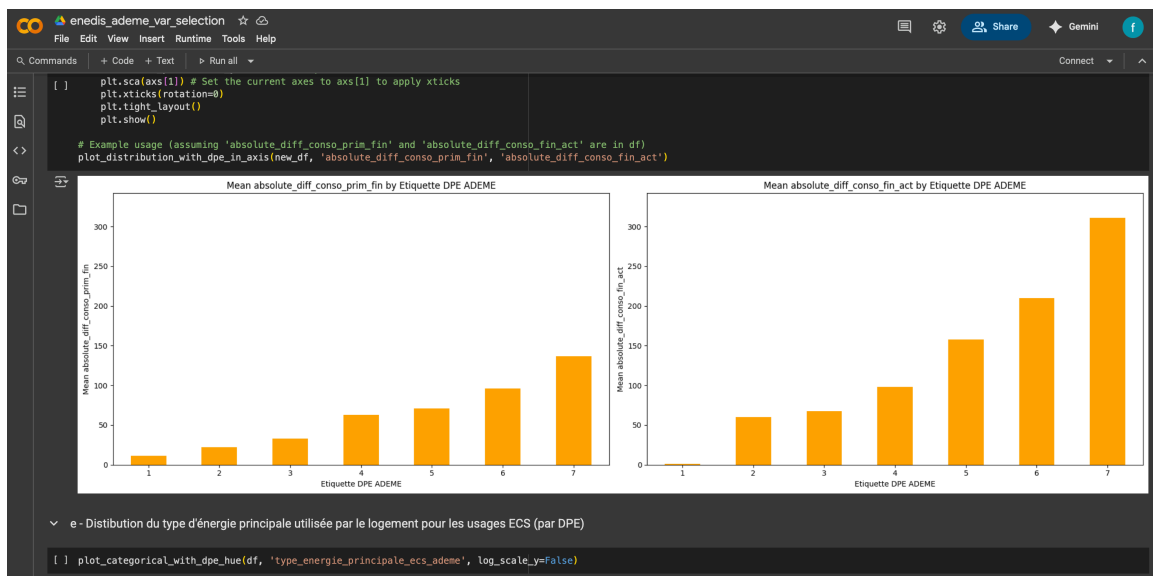


Figure 19 : Analyse exploratoire sur colab – 2




Figure 20 : Analyse exploratoire sur colab – 3




Figure 21 : MinIO UI - 1




Figure 22 : MinIO UI - 2