



Mastère Data Engineer

Titre RNCP 39586

Ingénieur en Science des Données – Spécialité

Infrastructure Data



RENDU BLOC 3 – Élaborer et Piloter un Projet Data

Juin 2025

**Sujet : Conception d'une Architecture Data pour
Analyser les Consommations d'Énergie
Réelles et la fiabilité des DPE des logements en France**

Réalisé par :

GBENOU Merveille Féréol Mahugnon

Introduction	2
A- CONTEXTE ET PROBLEMATIQUE	4
1- Le Diagnostic de Performance Énergétique et ses enjeux	4
2- Évolutions, limites et nécessité d'exploiter le big data	4
3- Problématique	5
B- DOCUMENTATION ET CADRAGE DU PROJET	5
1- Définition de la portée du projet et description de la solution proposée	5
2- Estimation du volume des données, contraintes, points de vigilance	9
3- Identification des ressources à allouer	9
4- Allocation des ressources, délai, faisabilité et planning des tâches	11
5- Méthode de gestion du projet	12
C- SUIVI DU PROJET ET GESTION DE L'EQUIPE	13
1- Outil de suivi de projet et méthode de suivi	13
2- Tableau de bord pour la gestion et le suivi du projet	13
3- Plan de développement des compétences	14
4- Les outils de communication et managériaux utilisés	15
5- Présentation d'un cas d'arbitrage lors de l'allocation des ressources	15
D- PLANS D'ACTION	15
1- Méthodologie de veille	15
2- Plan d'actions relatif aux enjeux RSE, de sécurité, éthique et de confidentialité	16
Conclusion	20
Annexes	21
Sources et liens	24
Figure 1 : Annexe - Schéma du SI du projet avec les différents modules.	22
Figure 2 : Annexe - Chronogramme des tâches - Diagramme de Gantt	22
Figure 3 : Annexe - Aperçu données de consommation Enedis	23
Figure 4 : Annexe - Tableau de bord suivi du projet 1/2	23
Figure 5 : Annexe - Tableau de bord suivi du projet 2/2	23
Figure 6 : Annexe - Architecture Médaille - Source Databricks	24
Figure 7 : Annexe - Aperçu des services du datalab SSP Cloud.	24
Tableau 1: Coût de l'infrastructure par mois selon les options de déploiement.	11
Tableau 2 : Allocation des ressources pour chaque phase du projet	11
Tableau 3 : Risques identifiés dans le cadre de ce projet	16
Tableau 4 : Annexe - Phases du projet, détail des tâches à réaliser, les rôles et les livrables	21

Introduction

Dans un contexte marqué par l'urgence de la transition écologique et l'impératif de réduction des consommations énergétiques, la fiabilité des outils d'évaluation énergétique des bâtiments représente un enjeu stratégique majeur. Ce document est rédigé dans le cadre d'un projet qui, en réponse à un challenge universitaire, propose une approche innovante basée sur l'ingénierie des données pour confronter les estimations théoriques des Diagnostics de Performance Énergétique (DPE) aux consommations électriques réelles des logements. En effet, la donnée constitue aujourd'hui le socle fondamental de toute stratégie d'optimisation énergétique. Dans le secteur du bâtiment responsable de près de 45% de la consommation énergétique nationale en France (Ministère de l'Aménagement du Territoire et de la Décentralisation), l'exploitation des données est déterminante pour identifier et quantifier les leviers d'économies d'énergie. Ainsi, la granularité et la qualité des données de consommation électrique peuvent par exemple permettre d'établir des corrélations entre les caractéristiques des bâtiments, les comportements des occupants et les consommations d'énergie réelles. Cette approche data-driven s'inscrit pleinement dans les objectifs de la Stratégie Nationale Bas-Carbone de la France publiée en 2018 qui vise une réduction de 50% de la consommation énergétique du parc immobilier à l'horizon 2050. L'analyse fine des écarts entre estimations théoriques et consommations réelles constitue un prérequis pour calibrer efficacement les politiques publiques de rénovation et dimensionner les aides financières associées.

En tant que gestionnaire du réseau de distribution électrique, Enedis dispose d'un patrimoine de données important sur les consommations électriques réelles des logements français notamment grâce à leur compteur Linky. Ces données représentent une source primaire pour estimer la consommation réelle d'énergie. Dans le cadre de sa mission de service public et de sa stratégie d'open data, Enedis a initié des programmes collaboratifs - notamment avec l'Open Data University - visant à mettre ces données à disposition de chercheurs et d'innovateurs pour développer des cas d'usage à fort impact sociétal.

La Base Adresse Nationale (BAN), pilotée par l'Institut National de l'Information Géographique et Forestière (IGN) en collaboration avec La Poste et OpenStreetMap France, constitue le référentiel géographique officiel des adresses du territoire français. Cette infrastructure essentielle permet d'associer précisément chaque bâtiment à ses coordonnées géographiques, donnant ainsi la possibilité de croiser avec d'autres jeux de données comme les caractéristiques socio-démographiques des quartiers ou les données climatiques locales. L'exploitation des données de la BAN dans l'architecture technique de ce projet permettra d'enrichir considérablement l'analyse des facteurs

exogènes influençant les consommations électriques, notamment les effets de localisation géographique et d'exposition.

L'Agence de la Transition Écologique (ADEME) quant à elle, centralise l'ensemble des Diagnostics de Performance Énergétique réalisés sur le territoire national. Cette base de données référentielle contient les caractéristiques techniques détaillées de millions de logements (surface, isolation, systèmes de chauffage, etc.) ainsi que les estimations théoriques de consommation énergétique établies selon la méthode 3CL. L'exploitation de ces données permet d'établir une cartographie précise du parc immobilier français selon les performances énergétiques théoriques. Cette donnée constitue la référence contre laquelle les consommations réelles mesurées par Enedis seront confrontées.

Dans ce contexte multi-acteurs caractérisé par la fragmentation des sources de données, notre équipe data nommée *Nexus* propose une infrastructure technique innovante capable d'intégrer, de normaliser et d'analyser ces multiples flux de données hétérogènes. L'ambition de l'équipe dans le cadre du challenge est double : d'une part, concevoir une plateforme data scalable et sécurisée capable d'ingérer et de traiter efficacement les données massives issues des compteurs communicants Linky, des DPE et des référentiels géographiques et d'autre part, développer des algorithmes d'analyse et de modélisation permettant de quantifier précisément les écarts entre consommations théoriques et réelles, d'identifier les facteurs explicatifs de ces écarts et de modéliser l'impact économique réel d'une amélioration de la classe DPE. Cette infrastructure technique permettra aux différentes parties prenantes (pouvoirs publics, professionnels de la rénovation, propriétaires et locataires) d'accéder à des indicateurs fiables et personnalisés pour éclairer leurs décisions d'investissement dans la rénovation énergétique.

Ce papier représente le premier livrable des quatre blocs de rendus dans le cadre de la certification RNCP Ingénieur en Science des Données – Spécialité Infrastructure Data. A travers ceci, nous partons de la problématique pour analyser le besoin et poser les bases de la gestion de ce projet Data. Dans un premier temps, ce document abordera le cadrage du projet, de même que son dimensionnement, le choix de la conception architecturale et l'analyse des ressources nécessaires à sa réalisation. Ceci permettra de conclure quant à la faisabilité du projet et débouchera sur le choix d'une méthode de gestion de projet. Dans un second temps, la stratégie de suivi du projet sera présentée à travers la méthode de suivi et le choix des outils de suivi et de communication. Une analyse des points forts et des points faibles des membres de l'équipe sera également réalisée pour établir un plan de développement de compétences. Enfin, les enjeux de sécurité, de confidentialité et d'éthique inhérents à la manipulation de données sensibles dans le respect de la réglementation sur la data et plus généralement un plan d'actions relatifs à la gestion des risques seront abordés dans un troisième temps.

A- CONTEXTE ET PROBLEMATIQUE

1- Le Diagnostic de Performance Énergétique et ses enjeux

Le Diagnostic de Performance Énergétique (DPE) est un document qui évalue la consommation énergétique d'un bâtiment et son impact sur l'environnement. Il attribue une étiquette allant de A à G pour chaque logement ou bâtiment, qui évalue sa consommation d'énergie d'une part (étiquette DPE) et son impact en termes d'émission de gaz à effet de serre (étiquette GES) d'autre part. Ceci permet d'identifier les logements dits "passoires énergétiques" c'est-à-dire ceux qui consomment le plus d'énergie ou émettent le plus de gaz à effet de serre.

Puisque le DPE donne une estimation attendue de la consommation d'énergie des logements, il a donc un double enjeu. Il est pertinent dans la mesure où il informe les propriétaires et les locataires sur la performance énergétique de leur logement les incitant ainsi soit à éviter les logements à forte consommation d'énergie (à l'achat/location) soit à réaliser des travaux de rénovation pour améliorer l'efficacité énergétique et ainsi réaliser des économies. Dans le premier cas, les personnes concernées réalisent des économies, dans le second cas, elles sont motivées à s'engager dans des travaux pour réaliser la transition énergétique en vue de réaliser des économies à terme.

2- Évolutions, limites et nécessité d'exploiter le big data

Introduit en juillet 2005 dans le cadre d'une directive européenne, le DPE a connu trois réformes majeures (2011, 2021, 2023) pour améliorer successivement sa fiabilité, intégrer la méthode de calcul 3CL et lui conférer une valeur juridique. Cette évolution constante répond aux nouvelles exigences environnementales, notamment l'interdiction de louer les logements classés G depuis janvier 2023, qui s'étendra aux logements F d'ici 2028.

En ce qui concerne le calcul de cet indicateur, deux méthodes coexistent : la méthode 3CL, dominante, qui évalue la performance énergétique selon les caractéristiques techniques du bâtiment (isolation, chauffage), et la méthode des factures, basée sur les consommations réelles pour les logements récents ou peu occupés. Bien qu'étant la plus utilisée, la méthode 3CL repose sur des calculs conventionnels standardisés qui ignorent les modes de vie et taux d'occupation réels, créant ainsi des écarts significatifs avec les consommations effectives.

Ces limitations expliquent les révisions constantes du DPE, notamment la réforme de 2021 qui avait déjà tenté de corriger les écarts entre estimations et réalité. Face à cette inadéquation persistante et aux enjeux de la transition énergétique soutenue par les aides gouvernementales, il devient crucial d'exploiter massivement les données DPE pour développer des métriques prédictives plus précises et accompagner efficacement la transition énergétique des ménages.

3- Problématique

C'est dans ce contexte que Enedis, en partenariat avec l'Open Data University (ODU) ont ouvert un défi intitulé : *« Évaluer l'impact de la classe de DPE sur les consommations électriques de logements et confronter les estimations issues des DPE à des mesures réelles »*.

Le but du défi, est de mettre en place une plateforme pour éclairer et motiver les acteurs de la transition écologique dans leur prise de décisions en mettant à leur disposition des analyses statistiques et des indicateurs clés. Concrètement, ce défi peut être décomposé en plusieurs sous questions business.

- Combien gagne-t-on sur ses factures d'électricité en euros chaque année à améliorer sa classe de DPE ?
- Les estimations de consommation électriques conventionnelles fournies dans les DPE reflètent-elles bien la réalité mesurée des consommations électriques ?
- Quelle est la variabilité restante due à l'hétérogénéité des modes de vie et taux d'occupation ?
- Quel est l'impact des caractéristiques du bâtiment ou des équipements sur la consommation électrique ?

Dans le projet dont ce document fait l'objet, l'équipe aura à concevoir et implémenter un Système d'Information (SI) organisé autour des données sur la consommation électrique (fournie par Enedis et complétée par la BAN et les bases de l'ADEME) afin de répondre à la problématique de ce défi. Le SI développé à cette occasion a pour nom de code *VOLT-DPE* (Validation Of Linky versus Theorical DPE).

B- DOCUMENTATION ET CADRAGE DU PROJET

1- Définition de la portée du projet et description de la solution proposée

Objectifs du projet au regard de la problématique

L'objectif global de ce projet est de concevoir le SI *VOLT-DPE*, de le développer et d'établir un plan de maintenance. Les travaux réalisés dans le cadre du projet permettront :

- D'éclairer les décisions de rénovation en quantifiant les gains potentiels associés à une amélioration de la performance énergétique d'un logement (amélioration de l'étiquette DPE).
- De se prononcer sur la conformité au réel des estimations de consommation électrique présentées dans les DPE par des comparaisons aux données de consommations réelles et de quantifier la partie de la consommation électrique variable due aux habitudes des personnes.

Analyse du besoin

L'analyse du besoin montre que pour répondre à ce défi, il faudrait disposer de workflows data pour récupérer :

- Les consommations d'électricité par adresses fournis par Enedis
- Les adresses normalisées fournies par la BAN
- Les caractéristiques des logements fournies par l'ADEME

Ceci permettra de construire une base de données complète car il n'en existe aucune cochant toutes ces cases actuellement. Ensuite, il faudrait un système de stockage de données pour la persistance et un tableau de bord analytique avec des métriques pour répondre aux questions posées par la problématique (objectifs). Enfin, puisque le tout constitue un système d'information, il faudra monitorer l'exécution pour pouvoir mieux débayer, identifier les goulots d'étranglement et améliorer les temps de réponse.

Le système d'information sera organisé en micro-services. L'équipe fait ce choix d'architecture car le projet répond au challenge universitaire de l'ODU. Pour cette raison, il doit pouvoir être repris par d'autres chercheurs qui travailleront sur le sujet au cours des prochaines éditions. Ainsi, l'architecture en micro-services aura l'avantage d'être composée de modules ; elle permettra aux prochains étudiants/chercheurs de prendre le module qui les intéresse (par exemple le module qui récupère la base de données complète) pour le plugger à leur solution et aborder le problème sous d'autres angles. De plus, en opérant ainsi, l'équipe aura la liberté d'amorcer le développement en local et pourra, une fois le challenge fini, migrer les services dans le cloud pour l'exposer au grand public selon l'échéancier. Seule l'application finale (app analytique avec les KPIs et les modèles) sera exposée à l'utilisateur sera propriété de l'équipe *Nexus*. Elle répondra aux problématiques de l'étude. Le module permettant de constituer la base de données complète, sera d'utilité publique.

Les micro-services proposés sur la base de l'analyse du besoin sont alors : un module d'extraction de données, un module de dashboard analytique, un module de de stockage de données (base de données) et un filestorage. A ceux-ci, on pourrait ajouter un serveur API pour interfacier entre le backend et le frontend (app analytique).

Identification des contraintes

Les principales contraintes portent sur le volume des données à traiter (développé dans la partie suivante) et le budget. Le budget que l'équipe pourra consacrer à la réalisation de ce projet est fortement limité car ce projet est réalisé dans le cadre d'un challenge

universitaire (Open Data University) sur l'année universitaire 2024-2025. Le coût de développement de la solution devra être quasi nul.

Description de la solution : fonctionnement

Le système d'information *VOLT-DPE* pourra se décomposer en deux parties : l'interface client et le serveur. Ce dernier contiendra et implémentera des micro-services. Il s'agira du service ETL, du serveur du SGBD et du service API.

- Étape 0 : Au démarrage du serveur, l'ETL est exécuté pour fournir une base de données initiale. Cet ETL fonctionnera comme suit ; l'Extraction consistera à requêter en batch la base de données Enedis (versionnée par année). Ceci fournira une liste d'adresses brute de points de livraisons avec des valeurs de consommation agrégées à l'année. Ensuite, à partir de ces adresses, des requêtes seront faites sur la Base Nationale des Adresses pour récupérer la version normalisée des adresses. Enfin à partir de ces adresses normalisées, des requêtes seront envoyées à l'API de l'ADEME qui expose elle-même un jeu de données avec les adresses normalisées au format BAN. Une fois le jeu de données complet, dans la partie Transformation, le typage strict sera fait de même que la normalisation, la sélection des variables pertinentes et l'anonymisation si nécessaire en partant des schémas de données. Enfin dans la partie Chargement (Load), les données seront envoyées sur le serveur de stockage de données. Toute cette première partie sera monitorée et aura un module dédié. Pour la sécurité de la base de données, le serveur sera interfacé avec une API REST simple avec des endpoints qui reprennent les opérations CRUD dont l'application client aura besoin. Ceci sera détaillé amplement dans la documentation technique qui fait l'objet d'un autre rendu.
- Étape 1 : L'utilisateur accède au système par l'interface client. Il devra choisir une ville et saisir une adresse. À partir de cette adresse, le système lui propose une liste de points de livraisons Enedis (adresses également) parmi les adresses existantes dans la base de données au lancement du système.
- Étape 2 : Si l'utilisateur est satisfait, il valide son choix en soumettant l'adresse finale choisie. Le système fournit des métriques sur la ville/arrondissement choisi(e) et les valeurs de variables similaires à celles des logements correspondant au point de livraison Enedis l'adresse choisie pour préparer la prédiction. L'utilisateur ajuste alors les valeurs et demande une estimation.
- Étape 2-bis : Si l'utilisateur demande une adresse ou une ville qui n'est pas dans le système, il peut forcer la mise à jour des données exposées par le serveur (en ciblant une ville en particulier, ou en téléchargeant une liste d'adresses spécifique). Techniquement, cette mise à jour implémente l'ETL comme au premier run à l'étape 0 qui aura servi à alimenter la base.
- Étape 3 : Une fois l'analyse demandée, le serveur qui embarque un modèle d'apprentissage, donne une estimation de la consommation réelle du client, la comparaison avec les seuils de la classe DPE saisie, et une estimation des économies réalisables en euros s'il changeait de classe DPE. Enfin, le serveur

fournira aussi des métriques pour réaliser des graphiques pour analyser la distribution de certaines variables et croiser les variables pour faire des analyses avancées.

Au cours du développement, les exécutions des workflows data et les appels API seront monitorées via un module dédié au monitoring à des fins d'optimisation et de maintenance du code. Ce fonctionnement est résumé par la Figure 1 en annexe.

Description technique et fonctionnelle des services

Les micro-services composant notre système d'information seront donc :

- **Un serveur de données (SGBD) :** fonctionnellement ce service sera destiné à stocker les données propres pour le besoin analytique. Les données seront organisées en tables (modèle relationnel). Les raisons de ce choix sont présentées dans le bloc dédié à l'élaboration de la stratégie de collecte des données. Techniquement, le service devra disposer d'une puissance de calcul suffisante pour stocker et réaliser les requêtes CRUD sur environ 15Go de données au plus (voir Estimation du volume des données)
- **Une application ETL (associé à un orchestrateur) :** fonctionnellement, ce service sera dédié à l'extraction et la fusion des données des sources identifiées pour créer une base de données complète. Techniquement, il s'agira soit d'un package ou d'une classe (pipeline) qui implémentera plusieurs fonctionnalités (logging, connexion au serveur et filestorage, requêtes en asynchrone, multithreading pour I/O etc.)
- **Un filestorage (fichiers lourds et sauvegarde modèle) :** pour stocker les fichiers de logs, fichiers intermédiaires, modèle d'apprentissage). Techniquement il devra disposer d'une capacité de stockage et de calcul suffisante pour exécuter des requêtes I/O dans différents buckets
- **Un système de monitoring et de tracing :** pour lire et afficher les logs analytiques et logs des modèles d'apprentissage. Techniquement, il s'agira d'un dashboard de monitoring de métriques. Les logs seront lus directement depuis le filestorage
- **Une API REST :** fonctionnellement, il sert de point d'entrée pour la partie serveur. C'est le module qui expose les endpoints à requêter pour accéder aux données et qui redirige vers les autres services. Techniquement, il s'agira d'une base de code qui sera exposée dans une API REST avec des couches de contrôle et d'accès
- **Une plateforme de Dataviz (livrable client) :** de manière fonctionnelle, elle permettra d'avoir des métriques et des résultats d'analyse sur la consommation d'énergie dans la ville choisie par l'utilisateur. En plus, l'outil permettra d'afficher sur une carte la répartition des logements identifiés et mappés dans les sources de données (pas la localisation précise, ni l'adresse mais juste la position du point de livraison avec le nombre de logements). Enfin, la dernière fonctionnalité de cette plateforme sera d'exposer un modèle d'apprentissage pour prédire les économies possibles en changeant de classe DPE toutes choses égales par ailleurs.

2- Estimation du volume des données, contraintes, points de vigilance

Techniquement, notre projet consiste à fusionner les DPE de logements et les données de consommation électrique d'Enedis par adresse pour obtenir un jeu de données complet exploitable. Cette fusion repose sur les adresses comme clé d'appariement, et implique la normalisation des adresses via l'API de la BAN. En termes de volumétrie à l'échelle de la France, environs 6 millions de logements seront traités pour les DPE ADEME et 400 000 adresses (points de livraisons) par an pour les consommations électriques d'Enedis. Dans les lignes qui suivent, quelques estimations sur le volume de données à traiter sont réalisées.

- Pour les DPE

Sachant qu'il y a 6 millions de DPE et qu'un DPE compte environs 200 variables réparties comme suit : environs 100 variables de type chaîne de caractères, environs 100 de type int64 ou float64. L'espace occupé par 1 seul DPE peut être estimé. Puisque 1 caractère dans une chaîne occupe environs 1 octet, que 64 bits font 8 octets et que 1 024 octets font 1 Ko :

$$(20 \text{ octets en moyenne/chaîne} * 100 \text{ variables}) + (8 \text{ octets} * 100 \text{ variables}) = 2\,800 \text{ octets}$$

Donc 1 seul DPE occuperait environs en moyenne 3 Ko. La totalité de la base DPE occuperait alors environs 18 Go. Autre approche : en re-typant toute l'info en chaîne de caractère dès le début, on obtient environs 14 Go si on suppose que les nombres font 5 caractères en moyenne.

- Pour les consommations Enedis (schéma data API Enedis cf. Figure 3)

Chaque année, il y a :

$$400\text{milles adresses} \times \text{environs } 10\text{octets/variable} \times 20\text{variables} = \text{environs } 0.08 \text{ Giga octets/an}$$

- Pour les identifiants de la BAN

Il s'agit juste d'un code alpha numérique d'une dizaine de caractères à ajouter aux deux sources de données pour établir la connexion. Donc les résultats ne sont pas significativement impactés.

En somme, le SI aura à traiter (à l'échelle de la France métropolitaine) entre 15 et 20 Giga Octets de nouvelles données bruts par an. Pour cette raison, les contraintes techniques identifiées portent sur la scalabilité de la solution proposée (capacité à supporter la montée en charge et garder un temps de réponse correct). L'équipe fera donc particulièrement attention à optimiser la base de code et choisir des solutions pour chaque service en prenant en compte ces aspects.

3- Identification des ressources à allouer

Ressources matérielles et logistiques

- Le DataLab de l'INSEE : dans le cadre de ce défi, l'Open Data University a mis à disposition le datalab SSP Cloud de l'INSEE. Il s'agit d'un environnement de travail stateless (suppression systématique des données à la fin d'une session) avec des

clusters et des IDE pour traiter des données à l'instar de google colab. L'avantage de ce datalab est que la plateforme est ouverte à plusieurs catégories d'utilisateurs notamment les chercheurs. L'inconvénient est qu'il n'y a pas les données disponibles en lien avec la thématique ni de moyen simple de se connecter aux APIs, comme mentionné dans l'analyse des besoins.

Outre ce datalab, l'équipe aura aussi besoin de :

- 1 ordinateur portable par personne pour le développement, la communication au sein de l'équipe
- Serveurs (ordinateur distants ou locaux) pour exécuter les modules du projet
- De forfaits internet pour la navigation, la recherche et la communication
- De stylos, feuilles papiers, tableaux pour expliquer et schématiser le fonctionnement du SI et réaliser les modélisations en théorie (matériel de bureau)

Puisque les modules du serveur backend et de l'app analytique seront amenés à être déployés sur le cloud l'équipe aura besoin d'un abonnement chez un cloud provider. De plus, la base de code sera hébergée sur GitHub. Il y faudra des machines virtuelles pour exécuter les pipelines de CI/CD. Enfin, dans le cadre de ce challenge, les membres de l'équipe travailleront à distance la plupart du temps et se retrouveront dans les locaux du Campus YNOV à Paris par moment.

Ressources humaines

Les parties prenantes identifiées dans le cadre du projet *VOLT-DPE* sont l'Open Data University (ODU) et notre équipe de travail *Nexus*. L'ODU jouera le rôle de client sur les phases finales du projet. L'équipe de travail est constituée de 3 personnes.

La charge de travail sera gérée par un Data Engineer, un Data Scientist et un Chef de projet pour coordonner. Ils travailleront à un rythme régulier de 2 journées complètes par semaine ce qui équivaut environs à 0.3 personne/jour. Ce projet ne nécessitera pas d'embaucher de testeurs car les cas de tests seront identifiés et automatisés au fil du projet.

Ressources financières, budget

La comparaison des options possibles pour l'implémentation de chacun des micro-services sera présentée dans le bloc 1 (document dédié à la partie technique). Le tableau suivant résume sans détailler les coûts envisageables si l'infrastructure de départ est développée en local dans des conteneurs (MVP) et que les services sont migrés peu à peu vers des hébergeurs cloud. L'hypothèse de base est que nous traitons 15Go de data chaque mois conformément aux estimations ci-dessus. Remarquons que la tarification des app runners varie selon que la plateforme connaisse beaucoup de trafic ou pas les premiers mois d'utilisation.

Tableau 1: Coût de l'infrastructure par mois selon les options de déploiement.

Tarif par mois	Infra. Locale	AWS Cloud	Azure Cloud
Filestorage	0	0.023\$/Go * 15Go * 3 (zones bronze + silver + gold)	0.02\$/Go * 15Go * 3
Registry	0	0.1\$/Go * 2Go RAM * 3 services	0.0167\$/Go * 2Go RAM * 3
Serveur SGBD	0	211\$ (> 15Go de stockage)	99\$ (> 15Go de stockage)
App Runners	0	102\$ * 3 (high traffic)	122\$ * 3 (pay as you go, avec scaling auto)
Coût total infra.	0€	212 à 518\$ (soit 186 à 455€)	100 à 466\$ (soit 88 à 410€)

Le coût des ressources humaines est évalué à 0 dans le cadre de ce projet (conformément aux contraintes présentées) car l'équipe est constituée d'étudiants prenant part au challenge de l'Open Data University. Ils ne percevront donc pas de rémunération financières (salaires) durant le projet.

Enfin, pour les phases 1 à 3 le coût de la connexion internet est évalué à 20 € par membre de l'équipe, donc 60 € au total par mois. Le budget alloué à la phase 4 dépendra du type de déploiement choisi et variera entre 60 et 466 € par mois.

4- Allocation des ressources, délai, faisabilité et planning des tâches

Le projet sera organisé en 4 phases. La phase 1 portera sur le développement d'une Proof Of Concept (POC) avec une base de code pour les différents modules, leur intégration, la conteneurisation, un déploiement en local et des pipelines de CI/CD. La phase 2, la plus longue, sera organisée autour du développement des fonctionnalités clés de chaque module. Lors de la phase 3, la partie logging/monitoring sera mise en place avec un dashboard et les tests dans les différents modules. Enfin, dans la phase 4, portera sur l'implémentation de scénarios de disaster recovery (roll back de déploiement, tests de surcharges, etc.) pour mettre le SI à l'épreuve et identifier les goulots et faiblesses ce qui permettra de mettre en place une stratégie de maintenance et trouver des axes d'amélioration. Les ressources à allouer à chacune de ces phases sont résumées dans le tableau ci-dessous.

Tableau 2 : Allocation des ressources pour chaque phase du projet

Phase du projet	Ressources humaines	Ressources matérielles ou non	Budget (Estimations basées sur le choix des technologies)
1-Développement POC de VOLT-DPE	Equipe Nexus	Matériel de bureau, Salle de travail – Ordinateurs, 1 compte GitHub, Docker – VS Code	60 €
2-Développement des key features de VOLT-DPE, analyses, modélisation	Equipe Nexus, ODU	Ordinateurs (dev local) - un abonnement cloud provider (optionnel)	Entre 60 et 466 € par mois
3-Implémentation de la méthodologie de tests dans les modules	Equipe Nexus	Ordinateurs – abonnement cloud provider – machines virtuelles pour les pipelines de CI	Entre 60 et 466 € par mois
4-Déploiement, stabilisation et maintenance	Equipe Nexus, ODU	Ordinateurs, 1 infrastructure cloud avec des serveurs app runners	Entre 60 et 466 € par mois

De plus, le Tableau 4 en annexe reprend toutes les différentes phases du projet avec le détail des tâches. Au regard de cette charge de travail, l'équipe a estimé que le projet pourrait être réalisé sur 5 mois (entre mars et août 2025) pour avoir un MVP complet et fonctionnel. A partir de cette estimation, elle a planifié ses activités sur la Figure 2 : Annexe - Chronogramme des tâches - Diagramme de Gantt.

A partir de ce diagramme de Gantt, le chemin critique peut être identifié. Pour rappel, il s'agit des activités pour lesquelles tout retard entraînerait un décalage dans le délai de réalisation du projet au global. Ainsi, la succession suivante constitue le chemin critique de notre projet :

Préparation des ressources et POC (phase 1) - Réalisation du workflow data module ETL (phase 2) - Intégration du workflow data dans l'API (phase 2) – Développement de l'interface de dataviz, modélisation (phase 2) – Monitoring et profiling de l'ETL (phase 3) – Intégration des tests (phase 3) – Déploiement CI/CD (phase 4).

5- Méthode de gestion du projet

Pour la gestion du projet, une méthode de gestion agile est utilisée puisque le projet est organisé en 4 phases distinctes avec un délai de quelques mois. L'agilité est plus pertinente que d'autres méthodes traditionnelles comme le cycle en V ou la méthode PERT. En effet, la première exigerait une progression séquentielle dans la réalisation des tâches sans possibilité par exemple de revenir en arrière aisément dans la réalisation des tâches tandis que la seconde demande de détailler les tâches en sous tâches et d'établir des dépendances entre elles avant même de commencer le projet, ce qui s'avère trop complexe et probablement inefficace pour un projet comme le nôtre.

Dans la famille des méthodes agiles, la méthode hybride entre scrum et kanban est celle qui est choisie. Pour chacune des phases, Kanban servira à identifier les points clés (par exemple pour la POC) et Scrum sera utilisée pour structurer les développements. L'équipe a fait ce choix car Scrum seul contraindrait dans la gestion urgente des aspects sécuritaires non envisagés au départ (obligation d'attendre le sprint suivant). L'approche hybride aiderait particulièrement pour les phases 3 et 4 où la complexité s'intensifie. La planification de sprints de Scrum aidera à structurer efficacement l'implémentation des tests et du monitoring. Au même moment, la dimension visuelle et le temps réel de Kanban permettront de suivre l'évolution des tests et d'identifier immédiatement les défaillances. Pour la phase 4 cette méthode permettra notamment d'amorcer le déploiement et les tests de surcharge en corrigeant les goulots identifiés. Cette méthode de gestion permettra aussi de faire des sprints reviews et d'identifier les axes d'amélioration pour préparer un plan de maintenance.

Enfin, puisque la méthode de gestion est basée en partie sur Kanban, le cycle de vie d'une tâche typique peut être schématisé. Elle commencerait dans la liste des « *Todo* », ensuite passe dans la liste des « *In progress* » puis dans To test une fois la *pull request* ouverte.

Enfin une fois les tests validés, un tag est released ce qui permet de versionner les développements (voir Figure 4 : Annexe - Tableau de bord suivi du projet 1/2 en annexe).

C- SUIVI DU PROJET ET GESTION DE L'EQUIPE

1- Outil de suivi de projet et méthode de suivi

Pour respecter les échéances, l'équipe a mis en place un système de suivi des tâches à réaliser lors de chaque phase du projet.

Parmi les solutions qui disponibles pour le suivi du projet, il y a des plateformes gratuites comme Trello, le gestionnaire de projet de GitHub ou encore les logiciels de versionning hébergés dans le cloud comme Azure DevOps. La plupart sont gratuits mais puisque le projet est open source sur GitHub et pour des raisons de simplicité d'utilisation, GitHub Project sera utilisé. Cet outil est pratique dans la mesure où il peut être relié aux repos GitHub. Par exemple, clore une *pull request* terminera automatiquement la tâche associée. Le code et l'outil de suivi de projet sont ainsi sur la même plateforme (cf. Figure 5 : Annexe - Tableau de bord suivi du projet 2/2).

En ce qui concerne la méthode de suivi du projet, l'équipe implémente la méthode RACI (voir Tableau 4 : Annexe - Phases du projet, détail des tâches à réaliser, les rôles et les livrables). Cette méthode permet de déterminer de manière claire et précise les rôles et les responsabilités de chaque membre de l'équipe. Ainsi chaque tâche technique aura un Responsable ou réalisateur (R), un approbateur (A) c'est à dire une personne (si possible) différente du réalisateur et de la personne consultée (C) et qui approuvera la tâche (décision finale sur le statut de la tâche). Enfin, il y aura la partie prenante à informer (I). Elle n'aura pas de rôle actif dans la réalisation de la tâche mais sera juste informée sur l'impact de sa réalisation sur le projet au global.

2- Tableau de bord pour la gestion et le suivi du projet

Le tableau de bord kanban (voir Figure 5 : Annexe - Tableau de bord suivi du projet 2/2) s'appuiera sur des métriques pour évaluer la charge de travail restante, en cours et déjà réalisée car il faudra probablement besoin de réallouer les ressources humaines ou concentrer les efforts de développement sur les phases critiques en cas de décalage dans le calendrier de réalisation. Pour ce faire, pour chaque personne de l'équipe de développement, le chef de projet devra mesurer les indicateurs suivants :

- Le nombre de tâches à faire (To do) pour évaluer la charge de travail restante
- Le nombre de tâches en cours (In Progress) pour évaluer les efforts en cours et réallouer ou équilibrer la charge de travail
- Le nombre de tests à réaliser (To test) pour évaluer le nombre de tests à réaliser (la plupart des tests sont automatisés via des pipelines)
- Le nombre de tags released pour évaluer les réalisations

En outre, tout au long du projet, chaque semaine, des échanges « one-to-one » avec le chef de projet seront organisés pour prendre en compte les besoins des membres de l'équipe et permettre la prise de décision en temps réel. De plus, à la fin de chaque phase, une session de debriefing sera organisée avec toute l'équipe pour récolter les avis sur le déroulé du projet, les points forts de l'équipe et les points faibles et les axes d'amélioration.

Les comptes rendus de réunions seront réalisés par le Chef de projet. Ceci permettra de documenter la réalisation du projet, de mieux préparer les phases suivantes et de valoriser leurs interventions et favoriser le bon fonctionnement de l'équipe.

3- Plan de développement des compétences

L'évaluation des compétences des membres de l'équipe a permis de dégager la liste des compétences actuelles des membres de l'équipe et les besoins de montée en compétence.

En effet, le Data Scientist maîtrise l'analyse statistique avancée et la modélisation de phénomènes économiques complexes, l'exploitation des datasets du projet pour répondre au besoin métier. Le Data Engineer a quant à lui une expertise en architecture de données et workflows data. Il s'occupe également de l'industrialisation des modules du projet via l'implémentation de bonnes pratiques de software engineering dans le code et la mise en place de l'infrastructure pour le déploiement en local. Le Chef de projet a de l'expérience en méthodologies agiles et en conception de tableaux de bord analytiques, garantissant le pilotage technique et la visualisation des métriques projet.

D'après cette liste de compétences, après concertation et au regard de la portée du projet les besoins de formation suivants ont été identifiés.

Data Engineer :

- Savoir concevoir une architecture de pipelines ETL cloud-native
- Orchestrer avec Prefect Flow et créer des packages
- Maîtriser Kubernetes pour déploiement containerisé, et éventuellement expertise Terraform pour Infrastructure as Code.

Data Scientist :

- Maîtriser d'un framework MLOps (MLflow)
- Optimiser des modèles de machine learning et détection de drift
- Certification sur les bases du cloud computing (AWS/Azure).

Chef de projet :

- Connaître et conseiller sur la méthodologie CRISP-DM pour projets data science, expertise en bases de données, analytics, AI/ML, et systèmes cloud
- Certification DevOps pour la partie CI/CD.

Plus généralement, toute l'équipe devra se former sur deux points en particulier : l'utilisation de l'Open data et la sensibilisation sur l'empreinte environnementale du

numérique (RSE). Ce sont des formations proposées par l'Open Data University gratuitement (liens vers les ressources à disposition, cf. sources du challenge en annexe).

4- Les outils de communication et managériaux utilisés

L'équipe compte 3 personnes/rôles. La répartition des tâches a été présentée dans l'allocation des ressources (cf. Allocation des ressources, délai, faisabilité et planning des tâches). Pour suivre l'avancement du projet, les membres de l'équipe communiqueront sur Microsoft Teams dans un canal dédié. Ce choix a été fait car c'est le moyen de communication principal utilisé par les membres de l'équipe avec l'école. C'est donc plus simple et pratique. Le chef de projet organisera des points hebdomadaires et les revues de code seront réalisées par le Data Engineer en raison de son profil Software Engineer pour maintenir la qualité des livrables.

5- Présentation d'un cas d'arbitrage lors de l'allocation des ressources

Un exemple d'arbitrage auquel il a fallu faire face lors de l'allocation des ressources est présenté dans la partie *Risques et plan de gestion de risque*.

D- PLANS D'ACTION

1- Méthodologie de veille

La méthodologie de veille choisie consiste d'une part à mettre en place un système de notifications sur les articles publiés sur internet pour être au courant de l'actualité sur les rénovations énergétique puisqu'il s'agit d'un sujet d'intérêt national avec la réglementation qui évolue constamment. Nos sources d'informations identifiées et validées par l'ODU (organisatrice du défi) sont les suivantes :

- **Google alertes** : recherche par mots clés et notifications à chaque nouvelle publication d'articles. Exemples de mots-clés techniques utilisés : DPE, rénovation énergétique, ETL/ELT, open data, big data, RSE, évaluer l'efficacité de modèles de prédiction, préparation des données, croisement de données difficile.
- **Medium** : articles publiés par des particuliers (point de vigilance sur les risques d'usurpation, vérifier les auteurs), constitue un bon départ pour une base de code surtout pour la partie modélisation.
- **Sites officiels** (défis.gouv, data.gouv, info.ademe, plateforme open data university) : ce sont les plateformes concernées par le projet et qui mettent à disposition de la documentation sur les bases de données, les API et le contexte du projet. Avec les ressources de l'open data, l'équipe est en communication avec des personnes expertes sur le sujet de la transition énergétique.
- Enfin, les travaux déjà réalisés par d'autres étudiant.es et google scholar : recueils d'articles scientifiques et travaux des pairs sur l'aspect analytique du projet.

L'implémentation de cette dernière méthode a permis de tirer des conclusions sur la faisabilité du projet. Alexandre Bertran (Mai 2024) a réalisé une étude scientifique sur l'impact de l'implémentation des DPE sur la consommation énergétique des logements entre 1990 et 2020. L'auteur cherchait à vérifier si les outils comme le DPE, améliorent l'efficacité énergétique et réduit les consommations en se basant sur l'étude de séries temporelles (données Enedis entre 1990 et 2020). Ses résultats montrent que la consommation énergétique des logements en France est restée stable depuis 1990, malgré une augmentation de 38 % du nombre de logements, et ce grâce aux nouvelles normes énergétiques. Le DPE a eu un impact positif, mais des disparités régionales subsistent, nécessitant un soutien accru pour les zones les plus énergivores.

2- Plan d'actions relatif aux enjeux RSE, de sécurité, éthique et de confidentialité

Plan d'évaluation de la qualité des livrables

Pour évaluer la qualité des livrables, des tests unitaires sont implémentés. Ils permettront de valider le bon fonctionnement des composantes clés de ce SI d'une part et de vérifier leur intégration et la non-régression d'autre part. Ces tests seront automatisés via des pipelines de CI (Continuous Integration) dans chacun des modules. Ces pipelines seront déclenchés à chaque pull request (clôture de tâche de développement) vers la branche principale du module et devront être validés à 100% avant de mettre à jour la branche principale. En plus des tests, des linters sont utilisés dans la partie CI pour attester de la propreté du code et de l'implémentation des bonnes pratiques python (PEP). Enfin, les nouvelles fonctionnalités seront documentées (changelogs à chaque release de module) et un historique des bugs rencontrés sera également documenté.

Risques et plan de gestion de risque

Tableau 3 : Risques identifiés dans le cadre de ce projet, natures et pistes de solutions

Risque	Nature	Piste de solution
Retard dans la livraison – décalage par rapport au diagramme de Gantt	Délai/temps	Mobiliser plus d'ETP – augmenter le nombre de personnes/jour (initialement à 0.3 – c'est-à-dire 2 jours complets par semaine)
Code exposé sur un VCS (logiciel de contrôle de version) public	Sécurité	Sécuriser les branches principales en instaurant des pull requests - faire des code reviews - organiser le code en modules séparés pour ventiler le risque sur un monorepos - mettre les identifiants dans les secrets des repos et/ou chez un gestionnaire tiers (key vault)
Risque de sécurité des modules une fois déployé (leak de mots de passe, tokens)	Sécurité	Instaurer des username, mots de passe ou tokens avec des droits pour l'utilisation des modules. Exemple (schéma) : l'API a seulement les droits de lecture dans la bdd (pas de droits admin) – l'API sert de pont entre autres appli et la bdd – l'app analytique a seulement les droits de lecture sur l'api avec un token (à durée de vie).
Risques RGPD, RSE et éthique	Données	(Développées dans la suite)

Le tableau ci-dessus recense les principaux risques identifiés pour la réalisation de ce projet et les solutions plausibles.

Arbitrage par rapport à la gestion de risque (réajustement et arbitrage)

Cette partie présente l'arbitrage qui a été fait au sujet du choix de la solution de versionning de code.

En effet pour ce projet, il faut un endroit où héberger le code pour faciliter la collaboration dans l'équipe et permettre aux autres chercheurs de reprendre des modules de la solution si besoin. Parmi les solutions qui se proposaient, il y avait GitLab, GitHub, et des versionneurs de code hébergés dans le cloud (Azure, AWS, GCP etc.). Au départ le choix s'était porté sur Azure DevOps à cause du panel de fonctionnalités disponibles (repos privés, exécution de pipelines de CI/CD, registry de packages, logiciel de gestion de projet intégré). Nous nous sommes ensuite rendu compte que seule la partie VCS d'Azure DevOps était gratuite et que les autres fonctionnalités étaient payantes avec des coûts croissants selon l'utilisation des ressources. Cela aurait obligé à réévaluer le budget du projet et à trouver des ressources pour financer cette partie clé. Or, l'équipe a des contraintes de coût car ce projet a été réalisé dans le cadre d'un challenge universitaire. Pour cette raison, le choix a été réorienté sur GitHub qui propose les mêmes fonctionnalités, avec l'option de laisser certains modules du SI ouverts au public. Ainsi, certaines parties du projet resteront open source au début et les parties portant sur l'exécution de pipelines CI/CD et le suivi de tâches se feront respectivement via GitHub Actions et le planificateur de tâches de GitHub.

Confidentialité, aspect éthique des données et RSE

Les principales sources de données utilisées dans le cadre de ce projet proviennent de l'open data. Il s'agit de données numériques accessibles à tous sans restriction technique, juridique ou financière. Elles sont produites par des organismes publics et privés - en l'occurrence ici, Enedis et l'ADEME - et sont disponibles dans des sources de données publiques respectant les principes de l'open data à savoir l'accès libre, le droit de les réutiliser et de les compléter pour tirer de la valeur (à but lucratif ou non).

L'open data étant fournie par les organismes publics et privés, nous serions tentés d'affirmer que ses principes favorisent la responsabilité des personnes comme nous qui souhaitent la ré-utiliser. En effet, ces données ont déjà fait objet d'anonymisation rigoureuse des données personnelles car les fournisseurs ne sauraient s'exposer à des sanctions de la CNIL. Mais, en croisant des sources différentes le risque de ré-identification existe constitue une menace pour un projet comme le nôtre, car la combinaison de plusieurs jeux de données apparemment anonymes peut parfois révéler des informations personnelles. La nature évolutive du consentement pose également un problème, les usages futurs des données pouvant dépasser le cadre initial d'autorisation.

Pour ces raisons, le plan d'action dans cette partie consiste à :

- S'assurer en continu que les sources de données utilisées respectent les droits des personnes concernées en termes de données personnelles (RGPD)
- Réfléchir à chaque étape de la constitution de la base de données finale à la question de l'anonymisation et au respect du caractère personnel des données
- Mettre en place une stratégie de veille avec sur les textes du RGPD.

Les lignes suivantes abordent quelques pistes de réflexion sur ce plan d'action.

Pour le premier point, les données de consommations Enedis, sont agrégées par point de livraison (quartier, rue, immeuble) et donc à aucun moment des consommations individuelles des logements des Français ne seront exploitées. Plus spécifiquement, lorsqu'il s'agira d'appartements, les données de consommation seront agrégées (somme ou moyenne par lots de 10 au moins) et lorsqu'il s'agira de maisons elles le seront également ou alors les données ne seront tout simplement pas disponibles. Ceci limite le risque d'identification des personnes (adresse) et de leurs habitudes de consommation. Ensuite, la Base Nationale des adresses (BAN), dans sa forme actuelle ne communique pas de nom ni d'informations personnelles. Elle ne tombe pas sous le coup du RGPD car les adresses postales sont considérées comme des données publiques par nature. Selon la documentation du site doc.adresse.data.gouv.fr, les adresses ne constituent pas des données à caractère personnel au sens strict du RGPD puisqu'elles ne permettent pas, à elles seules, d'identifier directement une personne physique spécifique. En effet, une adresse désigne un lieu géographique et peut être associée à plusieurs personnes, entreprises ou services. Par ailleurs, la BAN s'inscrit dans le cadre d'une mission de service public visant à améliorer la qualité des services postaux, la livraison et les interventions d'urgence. Cette mission d'intérêt public constitue une base légale reconnue par le RGPD pour le traitement de données. Enfin, selon le site *Politique de protection des données à caractère personnel - ADEME Infos* de l'ADEME, l'agence est clairement soumise au RGPD pour plusieurs raisons. En tant qu'établissement public à caractère industriel et commercial, elle est considérée comme un responsable de traitement qui collecte et traite des données à caractère personnel. Mais, leur note précise explicitement que *"l'ensemble des Traitements de Données personnelles mis en œuvre dans le cadre des Services accessibles respecte [...] le Règlement général sur la Protection des données (Règlement UE 2016/679) (« RGPD »)."* Dans la section sur les catégories de données collectées, le document mentionne *"données d'identification : aucune ; données de contact : aucune"*, ce qui suggère que l'ADEME limite déjà la collecte de données identifiantes, facilitant ainsi le processus d'anonymisation pour l'open data. Ainsi les données de l'ADEME sont anonymisées car elles ne contiennent pas d'information qui se rapporte à une personne physique identifiée ou identifiable (définition du RGPD).

Le second point concerne la manière dont les données sont collectées, traitées et exposées une fois collectées. Puisque les données prises de manière éparées ne semblent pas tomber sous le coup du RGPD, il est de la responsabilité de l'équipe de contrôler l'usage qui en est fait une fois combinées.

Pour cette raison, l'équipe choisit l'architecture big data médaillon (voir Figure 6 : Annexe - Architecture Médaillon - Source Databricks) organisée en 3 couches avec différents usages pour chaque couche.

- Couche bronze : elle sera constituée des données brutes collectées auprès des sources. Elle sera stockée sur le filestorage.
- Couche Silver : elle sera le résultat de la fusion des données brutes ; à ce niveau la donnée est la plus complète possible. Elle sera stockée sur le filestorage, servira pour la partie modélisation et ne sera jamais exposée directement au public.
- Couche Gold : la donnée sera exposée via des tables (logements et adresses). Les adresses seront encodées et ne seront jamais exposées complètement. L'utilisateur aura juste accès aux consommations et aux informations des logements. Cette couche sera stockée sur la base de données et sera exposée via les endpoints de l'API et accessible à l'utilisation (app analytique).

Pour le troisième point, il a été mis en place une stratégie de veille basée sur les alertes google comme vu dans la partie *Méthodologie de veille* de cette rubrique. Chaque début de semaine, les membres de l'équipe recevront un mail récapitulatif des articles, textes qui ont été publiés la semaine d'avant en lien avec les sujets RGPD et DPE.

Dans une optique de responsabilité environnementale, notre système d'information *VOLT-DPE* implémentera plusieurs mécanismes d'optimisation énergétique pour minimiser la consommation de ressources. Les options envisagées sont : un système de cache intelligent qui minimise les sollicitations répétées des sources de données ; lorsqu'une requête utilisateur a déjà été traitée pour une adresse donnée, le système exploite directement les résultats mis en cache dans les différents modules, réduisant ainsi la charge de calcul et l'empreinte carbone associée. Cette approche nécessite un dimensionnement adapté des ressources conteneurisées selon la taille du cache, avec possibilité de montée en charge verticale (scale-up) pour PostgreSQL et horizontale pour les serveurs API selon les besoins. D'autre part, le volet formation RSE des membres de l'équipe comprendra des modules dédiés aux enjeux du Green IT et des sessions de sensibilisation sur l'impact environnemental des pratiques de développement, garantissant une approche éco-responsable dans la conception et l'exploitation de la plateforme *VOLT-DPE*.

Conclusion

Ce document a présenté le cadrage méthodologique et la structuration complète du projet VOLT (Validation Of Linky versus Theoretical DPE). Le cahier des charges a été défini pour l'élaboration de cette infrastructure data dédiée à l'analyse des écarts entre DPE théoriques et consommations électriques réelles et les économies réalisables en prenant part à la transition énergétique. À travers cette planification détaillée, l'équipe de travail a posé les fondations pour la mise en œuvre du pipeline data multi-sources capable d'intégrer les flux Enedis (2 millions de points de mesure par an), les référentiels ADEME et les données géospatiales BAN.

En ce qui concerne la méthodologie de gestion et de suivi du projet, un tableau de bord a été élaboré. La méthode de pilotage est basée sur l'agilité (framework scrum-kanban) avec des KPIs techniques qui permettront de suivre en temps réel l'avancement du projet. Cette méthodologie est accompagnée par un plan de montée en compétences ciblé pour les trois membres de l'équipe du projet couvrant les technologies cloud, les bonnes pratiques de Data engineering, Software engineering, Data Ops et Green IT en environnement distribué.

Ce plan de projet établit les bases pour les livrables complémentaires à venir notamment le document "Résultats d'Étude DPE vs Consommations Réelles" (bloc 2) qui présentera l'analyse détaillée des écarts observés entre les estimations théoriques et les mesures effectives incluant les modélisations statistiques, les indicateurs métier développés, et la "Documentation Technique du SI VOLT-DPE" (bloc 1) qui exposera l'architecture technique implémentée, les spécifications des services développés, les schémas de données normalisés, ainsi que les procédures d'exploitation et de maintenance de l'infrastructure (bloc 4). Ce plan constitue ainsi la première partie des 4 rendus couvrant l'ensemble des dimensions de ce projet : conception méthodologique, résultats d'analyse et réalisation technique. Il garantit que l'exécution technique et l'analyse des données s'inscriront dans un cadre cohérent et maîtrisé pour maximiser la valeur des données au service de la transition énergétique du parc immobilier en France.

Annexes

- Tableaux et figures

Tableau 4 : Annexe - Phases du projet, détail des tâches à réaliser, les rôles et les livrables

	Liste des tâches	Rôles*				Livrables
		R	A	C	I	
Phase 1 - POC	Créer un compte GitHub pour héberger le projet	P	E	S	S	Releases v0 des images des micro-services
	Créer les repos des 3 micro-services : ETL, Application Client et API backend	P	E	S	S	
	Créer un compte sur un container registry	E	S	P	P	Schémas UML du SI
	Écrire les pipelines de CI/CD pour pusher et versionner les images docker	E	S	P	P	
	Mettre en place une base de code par module	E	S	P	P	Liste de fonctionnalités arrêtées (voir bloc 3 – ce document)
	Faire communiquer les modules dans un module parent (docker compose)	E	S	P	O	
Phase 2 – ETL	Mettre en place les scripts ETL (Utilisation locale et avec filestorage distant – logique de micro-service)	E	S	P	O	Release v1 des images package ETL, API et App Analytique
	Implémenter l'architecture médaillon en batch-processing et définir les schémas des tables					
	Mettre à jour l'image de l'ETL (release v1)	E	S	P	O	Fonctionnalités opérationnelles
Phase 2 – Client	Identifier les métriques à afficher sur le Dashboard et proposer une base de dataviz, Analyse	S	C	E	O	
	Organiser l'application client (pages, présentation)					Documentation technique de l'ETL (bloc 1)
	Mettre en place un modèle statistique qui explique les consommations électriques et permet de se prononcer sur la pertinence du DPE.	S	C	O	E	
Phase 2 – API	Mettre à jour l'image de l'app client	S	P	P	E	Releases notes (changelogs)
	Mettre en place le routeur ETL run en asynchrone	E	S		P	
	Mettre en place le routeur vers la base de données (init, tables, rôles, variables d'environnement, lecture, écritures dans les tables)	E	S	P	P	Rapport d'analyse avec les métriques et conclusions – étude de cas de la ville de Paris (bloc 2)
	Mettre en place le routeur vers le filestorage (lecture, écriture)	E	S	P	P	
Phase 3	Mettre à jour l'image de l'api backend (release v1)	E	S	P	O	Release v2 des images incluant les tests (bloc 1 et 4)
	Écrire les scripts des tests unitaires et d'intégration	S	E	P	P	
Phase 4	Écrire des pipelines de CI pour chaque module pour exécuter les tests à chaque push.	S	E	P	P	Manuel de maintenance et d'utilisation (bloc 4)
	Réaliser des tests de scalabilité (stress tests)	E	S	P	P	
Phase 4	Documenter l'utilisation de la plateforme pour un nouvel utilisateur	P	S	E	O	Perspectives d'évolutions

*Légende (Tableau 4) : Pour les rôles nous faisons intervenir toutes les parties prenantes identifiées dans les ressources humaines : l'Open Data University (O), le Chef de projet (P), le Data Engineer (E) et le Data Scientist (S). Les lettres R A C I font référence à la méthode de suivi de projet utilisée présentée dans la rubrique Outil de suivi de projet et méthode de suivi.




Figure 1 : Annexe - Schéma du SI du projet avec les différents modules.




Figure 2 : Annexe - Chronogramme des tâches - Diagramme de Gantt

annee	0	1	2
code_iris	2022	2022	2022
nom_iris	060290102	060290111	060290117
numero_de_voie	La Source	Croisette-Palm-Beach	Le Vieux Port-Les îles
indice_de_repetition	13	20	23
type_de_voie	None	None	None
libelle_de_voie	RUE	RUE	AVENUE
code_commune	LACOUR	LATOUR MAUBOURG	LAUGIER
nom_commune	06029	06029	06029
segment_de_client	Cannes	Cannes	Cannes
nombre_de_logements	RESIDENTIEL	RESIDENTIEL	RESIDENTIEL
consommation_annuelle_totale_de_l_adresse_mwh	60	110	57
consommation_annuelle_moyenne_par_site_de_l_adr...	70.96	251.986	94.023
consommation_annuelle_moyenne_de_la_commune_mwh	1.183	2.291	1.65
adresse	2.96	2.96	2.96
code_epci	13 RUE LACOUR	20 RUE LATOUR MAUBOURG	23 AVENUE LAUGIER
code_departement	200039915	200039915	200039915
code_region	06	06	06
tri_des_adresses	93	93	93
	60015	60023	60028

Figure 3 : Annexe - Aperçu données de consommation Enedis

task list					kanban board	Roadmap	+ New view
Filter by keyword or by field					Discard		
Title	Assignees	Status	Repository				
1 define versionning chart #1	fereol023	Release new tag	fereol023/DPE-Energy-Performance-Analysis				
2 setup submodules repositories #2	fereol023	Release new tag	fereol023/DPE-Energy-Performance-Analysis				
3 test recursive requirements installation #4	fereol023	Release new tag	fereol023/DPE-Energy-Performance-Analysis				
4 fix tag creation workflow #5		Release new tag	fereol023/DPE-Energy-Performance-Analysis-ETL				
5 ELT init integration wo security #9		Release new tag	fereol023/DPE-Energy-Performance-Analysis-ETL				
6 API init integration wo security #5		Release new tag	fereol023/DPE-Energy-Performance-Analysis-API				
7 API - validate init integration final #4	fereol023	Release new tag	fereol023/DPE-Energy-Performance-Analysis-API				
8 add greetings #1		Release new tag	fereol023/DPE-Energy-Performance-Analysis-API				
9 validate setup init integration #1		Release new tag	fereol023/DPE-Energy-Performance-Analysis-ClientApp				
10 proposition versionning chart #5	fereol023	Release new tag	fereol023/DPE-Energy-Performance-Analysis				
11 setup docker ci #4		Release new tag	fereol023/DPE-Energy-Performance-Analysis-ETL				
12 write reference pipeline for gitflows #3	fereol023	In Progress	fereol023/DPE-Energy-Performance-Analysis				

Figure 4 : Annexe - Tableau de bord suivi du projet 1/2

task list					kanban board	Roadmap	+ New view
Filter by keyword or by field					Discard	Save	
Todo 2	In Progress 1	To Test 1	Release new tag 11				
This item hasn't been started	This is actively being worked on	This has been completed	test recursive requirements installation				
DPE-Energy-Performance-Analysis-ETL #1 write pipelines for data extraction	DPE-Energy-Performance-Analysis #3 write reference pipeline for gitflows	DPE-Energy-Performance-Analysis #6 automate tag creation poc	DPE-Energy-Performance-Analysis-ETL #5 fix tag creation workflow				
DPE-Energy-Performance-Analysis-ETL #2 write pipelines for data transformation			DPE-Energy-Performance-Analysis-ETL #9 ELT init integration wo security				
			DPE-Energy-Performance-Analysis-API #5 API init integration wo security				
			DPE-Energy-Performance-Analysis-API #4 API - validate init integration final				
			DPE-Energy-Performance-Analysis-API #1 add greetings				
+ Add item	+ Add item	+ Add item	+ Add item				

Figure 5 : Annexe - Tableau de bord suivi du projet 2/2




Figure 6 : Annexe - Architecture Médaille - Source Databricks




Figure 7 : Annexe - Aperçu des services du datalab SSP Cloud.

Sources et liens

Source du challenge

- <https://defis.data.gouv.fr/defis/diagnostics-de-performance-energetique>
- <https://latitudes.notion.site/Saison-3-Espace-tudiants-Open-Data-University-c0c9d7d3c18e4de18be13733c70eda2d>

Études similaires existantes

- Alexandre Betran, Evaluation l'impact du Diagnostic de Performance Energétique (DPE) sur les consommations énergétiques des logements., Mai 2024

- Dataactivist, DPE vs consommation réelle : opacité sur les performances réelles du bâti public à Compiègne., Juillet 2024
- Diogo Christopher & al., Evaluer l'impact de la classe de Diagnostic de Performance Énergétique (DPE) sur les consommations électriques de logements et confronter les estimations issues des DPE à des mesures réelles : Charente Maritime., Mai 2024
- Greenwave, Dashboard avec des métriques sur les DPE dans la ville de Paris. , Juillet 2024
- Walmsley, Menard, Picard & al., Impact des Diagnostics de Performance Énergétique (DPE)., EISGI La Rochelle, Avril 2024
- anquetos/meteoviz-streamlit-app: Source of Streamlit application for French weather data requests and visualization

Articles en lien avec les DPE

- <https://www.effy.fr/renovation-energetique/zoom-sur-la-methode-de-calcul-en-2022>
- <https://www.bytebase.com/blog/postgres-hosting-options-pricing-comparison/>
- Généralités | Documentation (BAN) Foire aux questions | Documentation
- Diagnostics de Performance Énergétique | defis.data.gouv.fr
- https://www.ecologie.gouv.fr/sites/default/files/documents/Presentation_reforme_DPE_diagnostiqueurs_novembre_2021.pdf

Références techniques

- <https://db-engines.com/en/ranking>
- <https://www.talend.com/fr/resources/monolithic-architecture/>
- Container registry : How to Choose a Container Registry: The Top 9 Picks
- 14 outils d'orchestration de conteneurs pour DevOps Argo CD, qu'est-ce que c'est ?
- <https://azure.microsoft.com/fr-fr/pricing/details/app-service/windows/>
- <https://aws.amazon.com/fr/apprunner/pricing/>

Méthode de travail

- Présentation générale de CRISP-DM - Documentation IBM
- <https://bubbleplan.net/blog/matrice-raci/>
- <https://slack.com/intl/fr-fr/blog/productivity/methode-de-gestion-de-projet>

Livrables possibles (challenge Enedis-ODU)

- Data analyse - Calculer la consommation d'électricité en kWh/m²/an ou kWh/an par logement issue des données Enedis et la comparer avec les DPE proposés pour cette adresse. Réaliser des statistiques sur les distributions de ces écarts selon les types de logements (année de construction, qualité de l'isolation) et

d'équipements (type de chauffage et d'eau chaude sanitaire etc.) et commenter les résultats obtenus

- Datavisualisation - qui illustre le lien entre données de consommations estimées issues des DPE et issues des données Enedis et évaluent la variabilité non expliquée par le DPE : Boxplots, nuages de points, distributions, diagrammes de Sankey par niveau de consommation, ...
- Data analyse - qui reflète l'impact des classes de DPE (de A à G) sur les consommations électriques réellement mesurées. On cherchera en particulier à quantifier le gain en kWh/an et/ou en kWh/an/m² induit par une amélioration de classe DPE (passage de F à E, de E à D, etc...), pour chaque classe. On pourra ensuite valoriser ces gains en euros en prenant des hypothèses tarifaires. On pourra traiter différemment les logements selon leurs caractéristiques (type de chauffage notamment), ou encore faire intervenir d'autres variables explicatives. On pourra également produire ces analyses et visualisations en distinguant les usages (chauffage, eau chaude sanitaire, éclairage, refroidissement, autre).
- Data science - De manière plus exploratoire, essayer de prédire la consommation électrique des foyers français (en fonction du DPE, de l'adresse du logement et caractéristiques démographiques à notre disposition). Il est aussi possible d'imaginer une analyse de la contribution de chaque variable à la prédiction. Cela peut aussi être la construction d'un petit outil qui prédit les économies faites suite à une rénovation, modulées par des données météorologiques.